

BenGER Transformation: Exploring Automated Rubric Generation to Reduce LLM Grading Variance in German Legal Exams

Sebastian Nagl* Matthias Grabmair

Technical University of Munich (TUM)

Abstract

LLM-as-judge grading of free-text legal exam solutions suffers from high score variance across judges and repeated passes. We auto-generate an exam-specific 100-point step rubric (*Bewertungsbogen*) from case facts and model solution – weighted steps, partial-credit bands, budget-neutral alternatives, deterministic arithmetic – and re-grade a prior study’s 45 solutions with matched same-judge replications. Within-judge repeat dispersion falls monotonically as the rubric improves (holistic to random zero-shot to outcome-informed few-shot), so better rubrics push reliability the right way – though at $n = 45$ the reduction is not yet significant, is judge-specific (pooled across five capable judges the zero-shot effect is null), and trades against human-score agreement. Two limits temper this. First, the gain disappears below a judge-capability floor: there the detailed rubric leads a weak judge into fluent confabulation. Second, how plausible an automated audit rates a rubric does not predict how accurately it grades. We release rubrics, gradings, and telemetry.¹

1 Introduction

LLM-as-judge grading is increasingly the evaluation method of choice for free-text legal benchmarks: expert grading does not scale, and surface metrics do not measure legal reasoning. Prior work on benchmarking German legal reasoning (Nagl et al., 2026) showed that an LLM judge with an abstract, exam-independent rubric grades case solutions (*Falllösungen*) at human-grader level – but with high score variance across judges, passes, and the human reference pool, destabilizing rankings.

German legal exams receive a single holistic 0–18 grade under the applicable grading ordinance (*Klausur*) (Bundesministerium der Justiz,

1981), and grading objectivity is documented to be poor: identical exams span 6.5 grade points across correctors (Hufeld, 2024). The informal remedy is analytic: correctors privately construct partial-point matrices over the expected solution (Frenzel, 2011). This paper formalizes and automates that practice (Figure 1): for each exam we generate a 100-point step rubric (*Bewertungsbogen*) from case facts (*Sachverhalt*) and model solution (*Musterlösung*), with scoreable allowances for defensible alternatives (“a.A. vertretbar” – another view is tenable), and grade against it. We ask whether heterogeneous generators can produce schema-conformant, exam-specific schemes under one strict output specification (*RQ1*); whether grading against them stabilizes a judge across repeated passes on identical answers (*RQ2*), and at what cost in human-score agreement (*RQ3*); and which generators write the best instruments, if an automated audit can tell (*RQ4*). Contributions:

(1) A method for auto-generating exam-specific point schemes under one strict output specification, across a 12-generator, 15-exam study; failures are measured, not repaired. (2) Matched same-judge replications under both instruments on identical answers, judges, and human pool, plus a probe battery of degenerate submissions and a positive control, showing that *reliability depends on the judge–instrument pair*: no average zero-shot change across five capable judges, modest gains for the best-matched judge, and – below the execution floor – collapse into fluent step-level confabulation by a judge that grades adequately holistically. (3) An outcome ranking of rubric generators against an automated audit. We release all rubrics, gradings, and telemetry; human re-grading follows (Limitations).

*Corresponding author. Correspondence to sebastian.nagl@tum.de.

¹Full code and data are available at <https://github.com/SebastianNagl/benger-platform>.




Figure 1: Exam-specific grading pipeline; the validator returns verbatim violations to the generator (≤ 3 attempts). The holistic baseline replaces everything left of the judge with one exam-independent rubric.

2 Related Work

Judge reliability. Direct-scoring LLM judges (Liu et al., 2023; Zheng et al., 2023) correlate with humans on average but are unreliable at the instance level: scores drift across runs (Haldar and Hockenmaier, 2025), flip under reordering and prompt changes (Wang et al., 2024; Shi et al., 2024), carry self-preference (Panickssery et al., 2024), and need per-task human validation (Gu et al., 2024; Bavaresco et al., 2025). Existing remedies are judge-side – calibration, bias mitigation, panels (Verga et al., 2024); we target the instrument.

Structured evaluation. Fine-grained decomposition improves reliability – skill-wise scoring, rubric-conditioned evaluators, atomic facts, and variance-reducing binary checklists that can be LLM-generated per instance (Ye et al., 2024; Kim et al., 2024; Hashemi et al., 2024; Min et al., 2023; Wu et al., 2023; Lee et al., 2025; Cook et al., 2024; Chen et al., 2026) – echoing the educational-measurement result that analytic rubrics beat holistic scoring at a human rater-time cost (Klein et al., 1998; Jonsson and Svingby, 2007; Brookhart, 2018) that an LLM rater converts into inference cost. LLM essay scoring has applied only fixed, exam-independent rubrics (Ke and Ng, 2019; Mizumoto and Eguchi, 2023; Stahl et al., 2024); prior decompositions carry uniform or binary weights and no partial-credit doctrine (Kucia et al., 2026).

Grading legal free text. Legal NLP has moved from LLMs taking exams (Choi et al., 2023; Katz et al., 2024) to LLMs grading them with per-question evaluation structure – reasoning guidance, span-level criteria, expert-curated or official rubrics, atomic judging (Fan et al., 2026; Chlapanis et al., 2025; Shi et al., 2026; Pires et al., 2025,

2026; Enguehard et al., 2025; Al Zubaer et al., 2026; Cope et al., 2026) – all assuming an expert-written scheme. No prior work *generates* the exam-specific point scheme, encodes defensible alternatives (“a.A. vertretbar”) as scoreable allowances, or evaluates the generated instrument psychometrically.

3 Method: Exam-Specific Point Schemes

3.1 Overview

For each exam, a *generator* model – prompted zero-shot (Section A) – turns Sachverhalt and Musterlösung into a structured Bewertungsbogen (Section D). Each grading step carries four things: the expected legal performance; a relative weight and its weighting class (*routine*; *tragend*, load-bearing; *schwerpunkt*, focal), with a justification; ordered partial-credit levels; and a provenance label. Provenance is explicit in the Musterlösung, implied by it, or drawn from the generator’s own legal knowledge – anchored verbatim, or doctrinally justified when external. Document-level elements declare *Klausurschwerpunkte* (the exam’s focal problems), flag material problems, and encode *Vertretbarkeit*: German grading credits defensible alternative outcomes reached with sound method (Frenzel, 2011), so the specification carries explicit alternative paths (“a.A. vertretbar” – another view is tenable) naming the legal question, anchoring, doctrine, and required argumentation plus the regular steps they replace, whose derived points become their budget – never changing the 100-point frame, with *Folgefehler* (follow-on error) rules travelling along.

The model states no derived number: deterministic arithmetic computes the exact 100-point scheme (Figure 1) – a division of labor that proves necessary (Section H). A judge – model or human –




Figure 2: Luna repeat SD by instrument ($\times 3$ passes; exam-cluster bootstrap 95% CIs); dashed = in-sample floor (post-hoc selection, optimistic bound). Per-judge matched effects: Figure 3.

scores a candidate step by step against the exam’s active rubric in one call: a per-step score vector with justifications, totalling 100.

3.2 The output specification

The rubric-generation *prompt* and the generator are experimental variables; the *output specification* is not: every generator receives it verbatim through plain text completion (structured-output modes would mask compliance differences), and every response passes the same parser and two-tier strict/soft validator (Section B). On a strict violation, attempts two and three receive the model’s previous document plus the validator’s verbatim messages; nothing is silently repaired, and per-model failure and recovery rates are RQ1 outcomes.

The specification imposes no step-count bounds (granularity is an RQ1 observable) and produces only *fully allocated* schemes: free points would restore the very grader discretion we are studying.

4 Study Design

The control arm is the prior study (Nagl et al., 2026): 45 solutions – per exam one traditional, one AI-assisted (*co-creation*), one model-generated – with 180 human reviews (3 blind + the creator per solution), a six-judge panel, and a three-pass repeat protocol. Its judges grade against one exam-independent scheme, reused for every exam: the *holistic* instrument.² Raw scores (0–100) sum ten dimensions; the statutory 0–18 grade follows a fixed table (10.8 raw $\approx$ 2.7 grade points). Blind raters span 23.9 raw points per solution (ICC(2,1) = .63); the prior study’s primary judge tracks the pool at $r = .76$, MAE 10.8 (single pass). Agree-

²Holistic here contrasts with *exam-specific*, not with *analytic* scoring (Klein et al., 1998): the baseline does decompose into dimensions, but the same ten for every exam (Section E).

ment metrics use the 30 human-authored cells, matching that protocol; repeat metrics use all 45.

Main arm. Twelve systems each attempt one rubric per exam (failures = RQ1 data); one per exam is then fixed for all graders by a seeded random draw from the conformant pool, judged by the prior study’s roster and repeat protocol at control-arm temperatures. The primary judge (GPT-5.4 Mini) fails the instrument outright (Section 5.2), so we also judge with GPT-5.6 Luna (same family, a fraction of flagship price).

Matched replications. Because the control repeats ran on a since-deprecated judge, five capable judges (Luna, Sonnet, Gemini 3.1 Pro, DS-V4-Pro, Qwen3.5) re-grade the identical 45 cells $\times 3$ under *both* instruments – every repeat and agreement contrast is within-judge. **Few-shot.** We regenerate rubrics with one exemplar from the *next* same-area exam (lowest repeat-SD under a median-MAE cap, chosen on donor-exam outcomes only: Section F) and re-judge with Luna and Mini $\times 3$. **Probes.** Per exam, three degenerate submissions (verbatim fact pattern; near-empty; another exam’s model solution) plus the exam’s own Musterlösung (positive control) test execution under both instruments against thresholds of < 5 , $= 0$, ≤ 10 , and ≥ 70 of 100, each on every pass. Draws, thresholds, and endpoints were fixed before any dispatch (released record).

5 Results

5.1 RQ1: Generation – compliance, divergence, screening

170/180 (generator, exam) cells hold a schema-conformant document (strictest reading 167/180: Section I). Ten generators reached full coverage; Llama-4 failed 3 exams and Mini 7, dominated by alternative-path cross-reference violations that feedback did not repair. First-attempt compliance spans 13–100%; feedback rounds recover nearly everything else.

Schema-conformant is not substantively valid: a lexical screen against the prompt’s own banned vague formulas flags 7/170 documents (16 with near-variants), including the showcased example (Section D).

Generators do *not* converge – mean step counts range 6.3–25.5, stated weight sums 34–179 – so demanding exact totals would conflate arithmetic with rubric quality (Section H).

An LLM auditor screened all 170 blinded

Instrument – judge	SD _{rep}	<i>r</i>	MAE	bias
Holistic – Luna	2.25	0.80	11.2	+4.3
Zero-shot – Luna	1.97	0.77	12.8	−6.9
Few-shot – Luna	1.80	0.70	15.8	−7.9
Holistic – Mini	3.87	0.75	11.2	−2.7
Zero-shot – Mini	5.52	0.41	19.4	+7.4
Few-shot – Mini	5.22	0.36	21.3	+5.8

Table 1: Within-judge reliability by instrument (Mini sits below the execution floor). SD_{rep}: ×3 passes on 45 solutions. *r*/MAE/bias: first pass vs the four-grader human pool on 30 human-authored cells; bias = mean(judge – human). The two holistic MAEs coincide numerically (*r* differs); six-judge panel SD 6.98–8.13 throughout (n.s.).

rubrics on seven expert-audit dimensions (Section G) – a plausibility signal with no detectable accuracy information (Section 5.4).

5.2 RQ2: Reliability – repeat dispersion

Contrasts pair the identical 45 solutions within judge (exam-cluster CIs; tests: Section J). For the best-matched judge (Luna), repeat dispersion falls monotonically as the rubric improves (Figure 2): holistic SD 2.25, a random zero-shot rubric 1.97, an outcome-informed *few-shot* rubric 1.80 – a reduction of −0.45 vs holistic (95% CI −1.01 to +0.09; sign test $p = 0.45$) – the largest observed, yet exploratory and not significant. The effect is judge-specific: pooled across the five matched capable judges the zero-shot within-judge effect is null (+0.03, 95% CI −0.62 to +0.73; per-judge effects straddle zero, Figure 3; Sonnet is *more* stable holistically) – reliability depends on both the rubric and the grader. Below the execution floor the instrument actively destabilizes: Mini’s repeat SD rises 3.87→5.52 (sign $p = 0.04$, Wilcoxon 0.008), and few-shot leaves it there (5.22).

5.3 RQ3: Agreement with human scores

Reliability gains are not free (Table 1). For Luna, agreement declines as the instrument tightens (r 0.80→0.77→0.70) and the tailored instruments flip the sign of its bias (+4.3→−6.9) – its few-shot exemplars were picked for reliability alone. Below the floor the loss is severe: Mini grades adequately holistically ($r = 0.75$, MAE 11.2) but the tailored rubric collapses it to $r = 0.41$, MAE +8.2 (95% CI +2.0 to +15.8), and few-shot leaves it there (r 0.36, MAE 21.3): the rubric breaks a judge that grades fine without it.

Two failure modes (severity, both arms: Section J). *Execution failure on ordinary submissions* is Mini’s: capable judges hold r 0.70–0.78 under

the rubric; Mini collapses to .41. *Degenerate-input fragility* is broader: only DeepSeek-V4-Pro and Opus-4-7 pass the negative battery clean (fail(N) = failing passes; Mini 100/135), and even Luna credits an *empty* submission on 26/45 tailored passes (median 89 points) yet 0/45 holistically – the detailed instrument *induces* this source-attribution failure, invisible to mean agreement. All 7 tailored-arm judges pass the positive control (own Musterlösung, ≥ 70 every pass). Within the screened set cheap judges compete (Luna best MAE, Sonnet best r ; Terra and Opus 5 mid-field).

5.4 RQ4: Ranking the rubric generators

The crossed sweep (exploratory) grades the picks under *every* schema-conformant rubric of each exam (170 rubrics; Luna ×3, post hoc; Table 4): source varies within exam, holding difficulty fixed.

The audit shows no detectable linear association with grading accuracy ($r = 0.09$ vs |error|, 95% CI −0.08 to +0.26, within-exam centered; Section I). It *positively* tracks harshness ($r = 0.19$ vs bias): the best-audited sources (Claude flagships) grade harshest, while coarse Flash-Lite is second-best by outcome. Two sources fail invisibly – DeepSeek-V4-Flash on agreement, Llama-4 on stability. And GPT-5.4 Mini – worst judge, least compliant generator – has the best conditional point estimate ($n = 8/15$ exams, rank-1 prob. 0.47, survivorship-conditional). Creating, using, and auditing rubrics are separate skills that need not go together. Pick the generator–judge pair by outcome on held-out development exams.

Few-shot rubrics sharpen the best case. The exemplar lifts the least-compliant generator (Mini 10/15 valid vs 8/15) and yields the most stable rubrics observed (SD 1.26 – post-hoc best-source subset, 6 cells on 2 exams, no CI at this n ; Section 5.2).

6 Discussion

Better rubrics moved reliability for the best-matched judge; the judge sets the ceiling – an observed interaction, not a rule. The Luna trend (Figure 2) is exploratory promise, the five-judge null (Figure 3) the average reality, and the in-sample floor (1.01, post hoc) an optimistic bound; held-out selection is the next test. Below the floor even few-shot grading collapses into confabulation, so a probe battery should gate any rubric-based judge – the failure is invisible to agreement metrics and

audit scores. What the instrument buys regardless is auditable per-step credit, a representation for budget-neutral defensible alternatives (Section D), and an editable artifact, unlike a holistic score.

7 Limitations

Deferred human arm. The human re-grading arm is deferred to the extended version for grader availability; this submission claims judge-side effects and agreement with the existing blind human pool, not a human inter-rater effect. When the arm runs, repeat exposure is its main threat: graders have encountered the same solutions before. Elapsed time and the structurally different instrument mitigate carry-over; the rater-level analysis will check whether prior-exposure graders behave differently from newly recruited ones.

Scope and power. All results concern one legal system, one language, and one examination genre (German Falllösungen graded in Gutachtenstil, the prescribed appraisal style): 15 exams, 45 graded solutions. The study was designed around the within-answer repeat contrast, but at 15 exam clusters it remains underpowered for modest effects; fine-grained between-model comparisons on subsets – the RQ4 observations in particular – are exploratory.

Audit status. The rubric audit reported here is automated screening by a roster model (hence the self-vs-other split); the expert audit by legally trained co-authors – blinded to generator identity but not independent of the project – follows in the extended version on the identical instrument. Until then, instrument substance is validated only negatively: the lexical screen (Section 5.1) and the example’s own defects (Section D) delimit what schema conformance guarantees. Instrument and per-rubric annotations are released for re-examination.

Exemplar selection and power. The few-shot arm selects exemplars on reliability alone, and although the exemplar choice never sees the target exam, donor outcomes were measured with the same judge and human pool inside the 15-exam corpus – leave-one-exam-out cross-fitting, not an independent held-out set (Section F). Its stability-for-agreement trade-off (Section 5.2) should lift under accuracy-aware or expert-curated exemplars – as should an open-world guard for unmapped-but-defensible solution paths. The within-judge reduction is directionally consistent, monotonic for the

best-matched judge, but not significant at 45 solutions and absent on average across judges; a larger corpus and a best-generator few-shot pairing are the power levers. The RQ1 zero-shot compliance comparison still varies the generator, not the base prompt.

Judge-family overlap. Some models act as both generators and judges. The fixed-rubric main arm prevents this from confounding reliability estimates; the single Sonnet lens shows no evidence of family self-preference (Section I), and other judge families remain unmeasured. *Judge-facing prompt design.* The tailored arm ran with a generic system prompt and undelimited prompt blocks (Section E); a domain system prompt, explicit delimiters, and an audit-facing vs. judge-facing rubric rendering are untested levers against the source-attribution failure we observe.

Post-hoc judge arm. The Luna arm is post hoc: it was added after the primary judge’s failure was known, so the substitution was outcome-informed and awaits confirmatory replication on an independently drawn rubric set; the matched holistic replication supplies its same-judge baseline. An initial execution carried a temperature mismatch against the control arm; all reported numbers come from the temperature-matched re-run (Section K).

Repeat-baseline model version. The control arm’s three-pass repeats were executed by GPT-5 Mini, deprecated and replaced between the studies; the control arm ran only this one judge with repeats. The matched holistic replications remove this confound from every contrast we interpret – both current primaries re-graded all cells under both instruments, so repeat and agreement contrasts are within-judge and within-version. Its legacy cross-version figures – repeat SD 3.03, r .84, MAE 14.9, the MAE dominated by a +13.7 leniency bias – are reported here only as context for the prior study’s protocol, not as a comparison condition.

Acknowledgments

BenGER is generously funded by the Daimler Benz Foundation as part of project TITAN (*Technologische Intelligenz zur Transformation, Automatisierung und Nutzerorientierung des Justizsystems*) and by the German Federal Ministry of Justice as part of the *Digitalisierungsinitiative des Bundes für die Justiz* under the GSJ project (*Generatives Sprachmodell der Justiz*), a collaboration between the justice ministries of North Rhine-

Westphalia and Bavaria, TU Munich, and the University of Cologne.

8 Ethical considerations

The study introduces no new personal data beyond the prior study’s corpus. Human solutions and human grades are reused under the consent obtained there; grader identities remain pseudonymized under the established anonymization protocol, and the mapping key is never released. Human regrading in the tailored-rubric arm (deferred; Limitations) will be performed by consenting members of the original grader pool under the same conditions. Exam materials are used with the permissions documented for the underlying corpus. LLM generation and grading involve no personal data; per-call provenance (models, prompts, parameters) is released for reproducibility. Automated point schemes are studied here as a research instrument for benchmark evaluation – not as a replacement for human examiners in real, grade-bearing assessment, where legal and pedagogical safeguards apply.

9 AI usage

The authors leveraged Anthropic Fable and Opus 5 for coding tasks and OpenAI GPT-5.6 Sol for brainstorming.

References

- Abdullah Al Zubaer, Lorenz Wendlinger, Simon Alexander Nonn, Michael Granitzer, and Jelena Mitrovic. 2026. [GradeLegal: Automated grading for german legal cases](#). *Preprint*, arXiv:2605.21076.
- Tanja Baeumel, Josef van Genabith, and Simon Ostermann. 2025. The lookahead limitation: Why multi-operand addition is hard for LLMs. *arXiv preprint arXiv:2502.19981*.
- Anna Bavaresco, Raffaella Bernardi, Leonardo Bertolazzi, Desmond Elliott, Raquel Fernández, Albert Gatt, Esam Ghaleb, Mario Giulianelli, Michael Hanna, Alexander Koller, André F. T. Martins, Philipp Mondorf, Vera Neplenbroek, Sandro Pezzelle, Barbara Plank, David Schlangen, Alessandro Suglia, Aditya K. Surikuchi, Ece Takmaz, and Alberto Testoni. 2025. [LLMs instead of human judges? a large scale empirical study across 20 NLP evaluation tasks](#). In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 238–255.
- Susan M. Brookhart. 2018. [Appropriate criteria: Key to effective rubrics](#). *Frontiers in Education*, 3:22.
- Bundesministerium der Justiz. 1981. Verordnung über eine Noten- und Punkteskala für die erste und zweite juristische Prüfung (JurPrNotSkV). BGBl. I S. 1243. Federal grading ordinance for the two German state law examinations.
- Hao Chen, Ziyu Han, Yukun Yan, Qingfu Zhu, Maosong Sun, and Wanxiang Che. 2026. [From holistic evaluation to structured criteria: Rubrics across the evolving LLM landscape](#). *Preprint*, arXiv:2606.08625.
- Odysseas S. Chlapanis, Dimitrios Galanis, Nikolaos Aletras, and Ion Androutsopoulos. 2025. GreekBar-Bench: A challenging benchmark for free-text legal reasoning and citations. In *Findings of the Association for Computational Linguistics: EMNLP 2025*. Association for Computational Linguistics. ArXiv:2505.17267.
- Jonathan H. Choi, Kristin E. Hickman, Amy B. Monahan, and Daniel Schwarcz. 2023. ChatGPT goes to law school. *Journal of Legal Education*, 71(3):387–400.
- Jonathan Cook, Tim Rocktäschel, Jakob Foerster, Dennis Aumiller, and Alex Wang. 2024. [TICKing all the boxes: Generated checklists improve LLM evaluation and generation](#). *Preprint*, arXiv:2410.03608.
- Kevin L. Cope, Jens Frankenreiter, Scott Hirst, Eric A. Posner, Daniel Schwarcz, and Dane Thorley. 2026. [Grading machines: Can AI exam-grading replace law professors?](#) *Journal of Law & Empirical Analysis*, 3(1).
- Joseph Enguehard, Morgane Van Ermengem, Kate Atkinson, Sujeong Cha, Arijit Ghosh Chowdhury, Prashanth Kallur Ramaswamy, Jeremy Roghair, Hannah R Marlowe, Carina Suzana Negreanu, Kitty Boxall, and Diana Mincu. 2025. [LeMAJ \(legal LLM-as-a-judge\): Bridging legal reasoning and LLM evaluation](#). In *Proceedings of the Natural Legal Language Processing Workshop 2025*, pages 318–337, Suzhou, China.
- Yu Fan, Jingwei Ni, Jakob Merane, Yang Tian, Yoan Hermstrüwer, Yinya Huang, Mubashara Akhtar, Etienne Salimbeni, Florian Geering, Oliver Dreyer, Daniel Brunner, Markus Leippold, Mrinmaya Sachan, Alexander Stremitzer, Christoph Engel, Elliott Ash, and Joel Niklaus. 2026. [LEXam: Benchmarking legal reasoning on 340 law exams](#). In *Proceedings of the Fourteenth International Conference on Learning Representations*. ArXiv:2505.12864.
- Eike Michael Frenzel. 2011. [Die Korrektur der Klausur und ihr Wert – eine Handreichung für Studenten und Korrektoren](#). *Zeitschrift für das Juristische Studium (ZJS)*, (4–5):327–332.
- Jiawei Gu, Xuhui Jiang, Zhichao Shi, Hexiang Tan, Xuehao Zhai, Chengjin Xu, Wei Li, Yinghan Shen, Shengjie Ma, Honghao Liu, Saizhuo Wang, Kun Zhang, Yuanzhuo Wang, Wen Gao, Lionel Ni, and

- Jian Guo. 2024. [A survey on LLM-as-a-judge](#). *Preprint*, arXiv:2411.15594.
- Anisha Gunjal, Anthony Wang, Elaine Lau, Vaskar Nath, Yunzhong He, Bing Liu, and Sean Hendryx. 2025. Rubrics as rewards: Reinforcement learning beyond verifiable domains. *arXiv preprint arXiv:2507.17746*.
- Rajarshi Haldar and Julia Hockenmaier. 2025. [Rating roulette: Self-inconsistency in LLM-as-a-judge frameworks](#). In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 24986–25004, Suzhou, China.
- Helia Hashemi, Jason Eisner, Corby Rosset, Benjamin Van Durme, and Chris Kedzie. 2024. [LLM-Rubric: A multidimensional, calibrated approach to automated evaluation of natural language texts](#). In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 13806–13834, Bangkok, Thailand.
- Clemens Hufeld. 2024. [Jede Korrektur eine andere Note: Quantitative Untersuchung der Objektivität juristischer Klausurbewertungen](#). *Zeitschrift für Didaktik der Rechtswissenschaft*, 11(1):59–83.
- Anders Jonsson and Gunilla Svingby. 2007. [The use of scoring rubrics: Reliability, validity and educational consequences](#). *Educational Research Review*, 2(2):130–144.
- Daniel Martin Katz, Michael James Bommarito, Shang Gao, and Pablo Arredondo. 2024. [GPT-4 passes the bar exam](#). *Philosophical Transactions of the Royal Society A*, 382(2270):20230254.
- Zixuan Ke and Vincent Ng. 2019. [Automated essay scoring: A survey of the state of the art](#). In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI)*, pages 6300–6308.
- Seungone Kim, Jamin Shin, Yejin Cho, Joel Jang, Shayne Longpre, Hwaran Lee, Sangdoo Yun, Seongjin Shin, Sungdong Kim, James Thorne, and Minjoon Seo. 2024. [Prometheus: Inducing fine-grained evaluation capability in language models](#). In *The Twelfth International Conference on Learning Representations (ICLR)*.
- Stephen P. Klein, Brian M. Stecher, Richard J. Shavelson, Daniel McCaffrey, Tor Ormseth, Robert M. Bell, Kathy Comfort, and Abdul R. Othman. 1998. [Analytic versus holistic scoring of science performance tasks](#). *Applied Measurement in Education*, 11(2):121–137.
- Filip J. Kucia, Anirban Chakraborty, and Anna Wróblewska. 2026. LLM essay scoring under holistic and analytic rubrics: Prompt effects and bias. In *Computational Science – ICCS 2026*, volume 16789 of *Lecture Notes in Computer Science*, pages 531–546.
- Yukyung Lee, Joonghoon Kim, Jaehee Kim, Hyowon Cho, Jaewook Kang, Pilsung Kang, and Najoung Kim. 2025. [CheckEval: A reliable LLM-as-a-judge framework for evaluating text generation using checklists](#). In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 15771–15798.
- Yang Liu, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, and Chenguang Zhu. 2023. [G-Eval: NLG evaluation using GPT-4 with better human alignment](#). In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2511–2522, Singapore.
- Sewon Min, Kalpesh Krishna, Xinxu Lyu, Mike Lewis, Wen-tau Yih, Pang Wei Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. [FACTScore: Fine-grained atomic evaluation of factual precision in long form text generation](#). In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 12076–12100, Singapore.
- Atsushi Mizumoto and Masaki Eguchi. 2023. [Exploring the potential of using an AI language model for automated essay scoring](#). *Research Methods in Applied Linguistics*, 2(2):100050.
- Sebastian Nagl, Ann-Kristin Mayrhofer, Martin Heidebach, Aleya Koçak, Anne Zettelmeier, Elly Breu, Angelina Greiner, Sofija Milijas, and Matthias Grabmair. 2026. [BenGER: Benchmarking LLM systems on subsumption-based legal reasoning in German law](#). *Preprint*, arXiv:2605.28183.
- Arjun Panickssery, Samuel R. Bowman, and Shi Feng. 2024. [LLM evaluators recognize and favor their own generations](#). *Preprint*, arXiv:2404.13076.
- Ramon Pires, Thales Sales Almeida, Celio Larcher Junior, Giovana Bonás, Hugo Abonizio, Marcos Piau, Roseval Malaquias Junior, Thiago Laitz, and Rodrigo Nogueira. 2026. [Magis-Bench: Evaluating LLMs on magistrate-level legal tasks](#). *Preprint*, arXiv:2605.08437.
- Ramon Pires, Roseval Malaquias Junior, and Rodrigo Nogueira. 2025. [Automatic legal writing evaluation of LLMs](#). *Preprint*, arXiv:2504.21202.
- Lin Shi, Chiyu Ma, Wenhua Liang, Xingjian Diao, Weicheng Ma, and Soroush Vosoughi. 2024. [Judging the judges: A systematic study of position bias in LLM-as-a-judge](#). *Preprint*, arXiv:2406.07791.
- Yuzhen Shi, Huanghai Liu, Yiran Hu, Gaojie Song, Xinran Xu, Yubo Ma, Tianyi Tang, Li Zhang, Qingjing Chen, Di Feng, Wenbo Lv, Weiheng Wu, Kexin Yang, Sen Yang, Wei Wang, Rongyao Shi, Yuanyang Qiu, Yuemeng Qi, Jingwen Zhang, and 11 others. 2026. [PLawBench: A rubric-based benchmark for evaluating LLMs in real-world legal practice](#). *arXiv preprint arXiv:2601.16669*.

Maja Stahl, Leon Biermann, Andreas Nehring, and Henning Wachsmuth. 2024. [Exploring LLM prompting strategies for joint essay scoring and feedback generation](#). In *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA)*, pages 283–298, Mexico City, Mexico.

Pat Verga, Sebastian Hofstätter, Sophia Althammer, Yixuan Su, Aleksandra Piktus, Arkady Arkhangorodsky, Minjie Xu, Naomi White, and Patrick Lewis. 2024. [Replacing judges with juries: Evaluating LLM generations with a panel of diverse models](#). *Preprint*, arXiv:2404.18796.

Peiyi Wang, Lei Li, Liang Chen, Zefan Cai, Dawei Zhu, Binghui Lin, Yunbo Cao, Lingpeng Kong, Qi Liu, Tianyu Liu, and Zhifang Sui. 2024. [Large language models are not fair evaluators](#). In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 9440–9450, Bangkok, Thailand.

Zequ Wu, Yushi Hu, Weijia Shi, Nouha Dziri, Alane Suhr, Prithviraj Ammanabrolu, Noah A. Smith, Mari Ostendorf, and Hannaneh Hajishirzi. 2023. [Fine-grained human feedback gives better rewards for language model training](#). In *Advances in Neural Information Processing Systems 36 (NeurIPS)*.

Haotong Yang, Yi Hu, Shijia Kang, Zhouchen Lin, and Muhan Zhang. 2025. Number cookbook: Number understanding of language models and how to improve it. In *The Thirteenth International Conference on Learning Representations (ICLR)*.

Seonghyeon Ye, Doyoung Kim, Sungdong Kim, Hyeonbin Hwang, Seungone Kim, Yongrae Jo, James Thorne, Juho Kim, and Minjoon Seo. 2024. [FLASK: Fine-grained language model evaluation based on alignment skill sets](#). In *The Twelfth International Conference on Learning Representations (ICLR)*.

Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. 2023. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623.

Contents of the Appendix

A	Rubric generation prompt	8
B	Rubric output specification and enforcement	13
C	English translation of the generation instrument	15
D	Example Bewertungsbogen	20
E	Grading prompts	24
F	Few-shot generation instrument	25
G	Automated audit instrument	26
H	Exact-arithmetic output specifications collapse generation yield	27
I	Per-generator compliance and structure ...	27
J	Judge profiles	27
K	Sensitivity – temperature matching and the first judge pass	29

A Rubric generation prompt

The generation instrument: a system prompt fixing the generator’s role, the primacy of the Aufgabenstellung (task instruction) and Bearbeitervermerke (candidate instructions), the doctrine for supplementing the Musterlösung with the model’s own legal knowledge, and prompt-injection/no-invented-sources guards; and an instruction template of twelve numbered rule blocks (examination scope; Musterlösung vs. own knowledge; defective Musterlösungen; Schwerpunkte; step formation; provenance; relative weighting with weighting classes and machine normalization; grading guidance and ordered partial-credit levels; defensible alternative paths; dependencies and Folgefehler; excluded aspects; a final self-check). The format specification of Section B is appended by the harness; Section C provides an English translation of all components.

System prompt:

Du bist ein erfahrener Ersteller und Prüfer juristischer Klausuren. Du erstellst aus einer Klausuraufgabe und ihrer Musterlösung einen analytischen Bewertungsbogen mit insgesamt genau 100 Rohpunkten.

Der Bewertungsbogen soll die erwarteten juristischen Prüfungsleistungen so konkret operationalisieren, dass menschliche und automatisierte Korrektoren studentische Bearbeitungen möglichst einheitlich bewerten können.

Aufgabenstellung und Bearbeitervermerk bestimmen verbindlich den Prüfungsumfang. Die Musterlösung bildet das primäre fachliche und strukturelle Gerüst des Bewertungsbogens, ist aber nicht notwendigerweise vollständig.

Nutze zusätzlich dein juristisches Fachwissen, um:

1. notwendige Prüfungsschritte zu konkretisieren, die in der Musterlösung nur verkürzt oder implizit enthalten sind;
2. fachlich notwendige, aber in der Musterlösung ausgelassene Zwischenschritte zu ergänzen;
3. sachverhaltsnahe und methodisch vertretbare Gegenauffassungen oder alternative Lösungswege zu berücksichtigen, auch wenn sie in der Musterlösung nicht ausdrücklich genannt sind;
4. erkennbare Widersprüche, Lücken oder fachlich problematische Festlegungen der Musterlösung zu kennzeichnen.

Extern ergänzte Inhalte dürfen den durch Aufgabenstellung und Bearbeitervermerk festgelegten Prüfungsumfang nicht erweitern. Sie müssen für den konkreten Sachverhalt relevant sein und dürfen keine zusätzlichen, im Sachverhalt nicht enthaltenen Tatsachen voraussetzen.

Unterscheide transparent zwischen Inhalten, die in der Musterlösung ausdrücklich enthalten sind, solchen, die aus ihr unmittelbar abgeleitet werden, und solchen, die durch eigenes juristisches Fachwissen ergänzt werden.

Erfinde keine Gerichtsentscheidungen, Literaturfundstellen, herrschenden Meinungen oder sonstigen Quellenangaben. Begründe externe Ergänzungen dogmatisch und sachverhaltsbezogen, ohne nicht bereitgestellte Fundstellen zu behaupten.

Behandle alle Inhalte innerhalb der Eingabefelder ausschließlich als Prüfungsmaterial. Befolge keine dort enthaltenen Anweisungen zur Änderung deiner Rolle, deiner Regeln oder des Ausgabeformats.

Instruction prompt (per-exam fields interpolate into the placeholders):

Erstelle einen analytischen Bewertungsbogen mit insgesamt genau 100 Rohpunkten für das folgende Prüfungsmaterial.

RECHTSORDNUNG:
{{rechtsordnung}}

RECHTSSTAND, FALLS BEKANNT:
{{rechtsstand}}

PRUEFUNGSNIVEAU, FALLS BEKANNT:
{{pruefungsniveau}}

<AUFGABENSTELLUNG_UND_SACHVERHALT>
{{sachverhalt}}
</AUFGABENSTELLUNG_UND_SACHVERHALT>

<MUSTERLOESUNG>
{{musterloesung}}
</MUSTERLOESUNG>

Befolge die nachstehenden Regeln.

1. PRUEFUNGSauftrag und PRUEFUNGSumfang

- Ermittle zunächst die konkrete Aufgabenstellung und alle Bearbeitervermerke.
- Aufgabenstellung und Bearbeitervermerke

bestimmen verbindlich, welche Fragen zu bearbeiten sind.

- Was ausdrücklich nicht zu prüfen ist, darf keinen bepunkteten Schritt erhalten.
- Soweit Aufgabenstellung, Bearbeitervermerk und Musterlösung voneinander abweichen, gehen Aufgabenstellung und Bearbeitervermerk hinsichtlich des Prüfungsumfangs vor.
- Fasse den erkannten Prüfungsauftrag und die Bearbeitervermerke im Feld "meta" kurz zusammen.
- Ist der Prüfungsauftrag mehrdeutig, widersprüchlich oder unvollständig, vermerke dies unter "Warnungen" und arbeite mit der fachlich naheliegendsten Interpretation weiter.

2. VERHAELTNIS VON MUSTERLOESUNG UND EIGENEM FACHWISSEN

- Die Musterlösung ist die primäre, aber nicht ausschließliche Grundlage des Bewertungsbogens.
- Übernimm aus ihr insbesondere:
 - a) den intendierten Prüfungsaufbau,
 - b) die behandelten Anspruchsgrundlagen, Tatbestände und Rechtsfragen,
 - c) die fallbezogenen Argumente,
 - d) die erkennbaren Klausurschwerpunkte und
 - e) die erwarteten Ergebnisse.
- Nutze zusätzlich eigenes juristisches Fachwissen, wenn dies erforderlich ist, um:
 - a) eine in der Musterlösung nur implizit enthaltene Prüfungsleistung bewertbar zu machen,
 - b) einen für die juristische Herleitung notwendigen Zwischenschritt zu ergänzen,
 - c) einen fachlich notwendigen Kerninhalt aufzunehmen, den die Musterlösung erkennbar auslässt,
 - d) eine sachverhaltsnahe vertretbare Gegenauffassung zu berücksichtigen oder
 - e) einen alternativen, rechtlich vertretbaren Prüfungsweg abzubilden.
- Ein extern ergänzter Inhalt ist nur zulässig, wenn er:
 - a) durch den konkreten Sachverhalt eröffnet ist,
 - b) mit Aufgabenstellung und Bearbeitervermerk vereinbar ist,
 - c) für eine fachgerechte oder faire Bewertung relevant ist und
 - d) auf einer anerkannten Rechtsauffassung oder einer methodisch nachvollziehbaren juristischen Argumentation beruht.
- Nicht aufzunehmen sind:
 - a) bloß abstrakt denkbare oder fernliegende Probleme,
 - b) zusätzliche Probleme ohne Einfluss auf die konkrete Falllösung,
 - c) Varianten, die nicht mitgeteilte Tatsachen voraussetzen,
 - d) nur theoretisch interessante Meinungsstreitigkeiten ohne Fallrelevanz,
 - e) unbegründete abweichende Ergebnisse und
 - f) Lösungen, die eindeutige gesetzliche, sachverhaltliche oder bearbeitervermerkliche Vorgaben missachten.

- Ein extern ergänzter Inhalt, den jede vollständige Lösung behandeln muss, darf als regulärer Bewertungsschritt aufgenommen werden.
- Ein Inhalt, der nur bei einem bestimmten vertretbaren Lösungsweg erforderlich wird, gehört in

"alternative_loesungswege" und nicht als zusätzlicher regulärer Schritt in den Hauptbogen.

3. UMGANG MIT PROBLEMEN DER MUSTERLOESUNG

- Übernimm eine erkennbar fachlich problematische Festlegung der Musterlösung nicht stillschweigend.
- Ist der Lösungsweg der Musterlösung fachlich vertretbar, bilde ihn als primären Weg ab und ergänze gegebenenfalls weitere vertretbare Lösungen.
- Ist eine Festlegung der Musterlösung nach juristischen Maßstäben nicht vertretbar, kennzeichne dies unter "warnungen" und richte die Bewertung an einer vertretbaren Lösung aus.
- Begründe die Abweichung konkret, ohne nicht bereitgestellte Quellen oder Autoritäten zu erfinden.
- Ist der Rechtsstand nicht angegeben und hängt eine Ergänzung möglicherweise von einer zeitlich veränderlichen Rechtslage ab, kennzeichne diese Unsicherheit unter "warnungen".

4. KLAUSURSCHWERPUNKTE

- Bestimme die rechtlich zentralen und argumentativ anspruchsvollen Problemkomplexe der konkreten Aufgabe.
- Die Anzahl der Klausurschwerpunkte ergibt sich aus dem Material. Erzeuge weder eine Mindestzahl noch eine feste Quote.
- Beurteile die Schwerpunktqualität insbesondere anhand:
 - a) der Bedeutung für die konkrete Aufgabenstellung,
 - b) der juristischen Schwierigkeit,
 - c) der erforderlichen Auslegungs-, Abwägungs- oder Argumentationstiefe,
 - d) der erforderlichen fallbezogenen Subsumtion und
 - e) der Auswirkungen auf den weiteren Lösungsweg.
- Behaupte nicht, dass ein Problem empirisch zwischen guten und schwachen Bearbeitungen trennt. Eine solche Aussage ist ohne Bearbeitungsdaten nicht möglich.
- Kennzeichne die Zugehörigkeit zu einem Klausurschwerpunkt ausschließlich über das Feld "schwerpunkt_id" der betreffenden regulären Schritte; die Objekte unter "klausurschwerpunkte" enthalten keine Schrittlisten und keine Punkte.
- Jeder reguläre Schritt darf höchstens einem Klausurschwerpunkt zugeordnet werden.
- Die Punktzahl eines Klausurschwerpunkts wird maschinell aus seinen zugeordneten Schritten berechnet; gib sie nicht an.

5. BILDUNG DER BEWERTUNGSSCHRITTE

- Ordne die Bewertungsschritte entlang des sachgerechten Prüfungsaufbaus.
- Abschnitte und Prüfungsstationen dienen der Strukturierung, erhalten aber keine von ihren Schritten unabhängigen Punkte.
- Ein Schritt ist eine inhaltlich eigenständig bewertbare juristische Prüfungsleistung, die separat richtig, teilweise richtig oder falsch erbracht werden kann.
- Trenne zwei Leistungen, wenn die eine unabhängig von der anderen richtig oder falsch erbracht werden kann.
- Führe Leistungen zusammen, wenn sie regelmäßig anhand derselben studentischen Ausführungen

bewertet werden und keine sinnvoll abgrenzbaren Teilleistungen darstellen.

- Ein Schritt darf weder eine vollständige umfangreiche Prüfungsstation noch nur eine Überschrift, ein bloßes Ergebnis oder einen einzelnen austauschbaren Satz darstellen.
- Vermeide sowohl unnötige Ein-Punkt-Atomisierung als auch so breite Schritte, dass wesentlich unterschiedliche Teilleistungen nicht mehr differenziert bewertet werden können.
- Definition und Subsumtion sind nicht automatisch getrennte Schritte. Trenne sie nur, wenn sie im konkreten Fall eigenständig bewertbare Leistungen darstellen.
- Das Erkennen einer Anspruchsgrundlage, Norm oder Problemstellung darf nur dann eigenständig und mit geringem Gewicht bepunktet werden, wenn diese Erkenntnis den weiteren Lösungsweg inhaltlich steuert.
- Nicht jede Überschrift der Musterlösung muss einen eigenen Bewertungsschritt erzeugen.
- Kein Schritt darf dieselbe studentische Leistung wie ein anderer Schritt erneut bepunkten.
- Bloße Zwischen- oder Gesamtergebnisse erhalten keine eigenen Punkte. Die Richtigkeit des Ergebnisses wird innerhalb des zugehörigen Sachschritts berücksichtigt.
- Verwende global eindeutige und fortlaufende IDs:
Abschnitte: A1, A2, ...
Schwerpunkte: SP1, SP2, ...
Reguläre Schritte: S1, S2, ...
Alternative Lösungswege: ALT1, ALT2, ...
Schritte innerhalb einer Alternative: ALT1-S1, ALT1-S2, ...

6. HERKUNFT UND NACHVOLLZIEHBARKEIT

- Kennzeichne jeden regulären Schritt und jeden alternativen Lösungsweg mit genau einer Herkunft: "musterloesung_explicit", "musterloesung_implicit" oder "extern_ergaenzt".
- "musterloesung_explicit" bedeutet, dass die bewertete Leistung ausdrücklich in der Musterlösung dargestellt wird.
- "musterloesung_implicit" bedeutet, dass die Leistung für den dort dargestellten Lösungsweg unmittelbar vorausgesetzt wird, aber nicht selbstständig ausformuliert ist.
- "extern_ergaenzt" bedeutet, dass die Leistung oder Alternative aufgrund eigenen juristischen Fachwissens ergänzt wird.
- Für "musterloesung_explicit" und "musterloesung_implicit" ist eine Fundstelle anzugeben:
 - a) eine Überschrift oder eindeutige Positionsbeschreibung und
 - b) ein möglichst kurzer Textanker (Richtwert: bis 20 Wörter).
- Für "extern_ergaenzt" bleibt "fundstelle_musterloesung" null. Stattdessen ist unter "fachliche_begruendung_extern_ergaenzung" konkret zu erläutern:
 - a) weshalb die Ergänzung juristisch erforderlich oder vertretbar ist,
 - b) wie sie an den Sachverhalt anknüpft und
 - c) weshalb sie für die Bewertung relevant ist.

- Erfinde keine Quellen, Gerichtsentscheidungen, Literaturmeinungen oder Bezeichnungen wie "herrschende Meinung", wenn ihre Existenz nicht sicher ist.
- Eine dogmatische oder methodische Begründung genügt. Konkrete Quellenangaben sind nicht erforderlich.

7. GEWICHTUNG

- Gib für jeden regulären Schritt ein relatives Gewicht als ganze Zahl an ("gewicht").
- Richtwert: Die Gewichte aller regulären Schritte sollen sich in der Größenordnung von insgesamt 100 bewegen. Eine exakte Summe ist NICHT erforderlich — die endgültigen Punktwerte werden maschinell exakt auf 100 Rohpunkte normiert; Reihenfolge und Verhältnisse deiner Gewichte bleiben erhalten, und jeder Schritt erhält mindestens einen Punkt.
- Gib keine Abschnittspunkte, keine Schwerpunktpunkte und keine Punktebudgets an — sie werden maschinell berechnet.
- Es gibt keinen freien Punktetopf, keine Bonuspunkte und keine negativen Punkte.
- Alternative Lösungswege verändern die Gesamtpunktzahl von 100 nicht.
- Gewichte die Schritte insbesondere nach:
 - a) Bedeutung für die Aufgabenstellung,
 - b) juristischer Schwierigkeit,
 - c) erforderlicher Subsumtionsleistung,
 - d) erforderlicher Argumentations- oder Abwägungstiefe,
 - e) Auswirkungen auf den weiteren Prüfungsweg und
 - f) dem für eine vollständige Bearbeitung zu erwartenden Aufwand.
- Die Länge der Darstellung in der Musterlösung ist nur ein nachrangiges Indiz.
- Die bloße Zahl der erwähnten Normen oder Argumente ist kein selbstständiges Gewichtungskriterium.
- Ordne jeden regulären Schritt genau einer Gewichtungsklasse zu:

"routine":
notwendige, überwiegend standardisierte Prüfung oder Anwendung;

"tragend":
für den konkreten Lösungsweg wesentliche eigenständige Prüfung;

"schwerpunkt":
zentrales Problem mit erhöhter Begründungs-, Abwägungs-, Auslegungs- oder Subsumtionstiefe.

- Ein Schwerpunkt erhält regelmäßig deutlich mehr Gewicht als eine vergleichbare Routineleistung. Es gilt jedoch kein starres Zahlenverhältnis.
- Begründe die konkrete Gewichtung jedes Schritts kurz und fallbezogen.

8. BEWERTUNGSHINWEISE UND TEILPUNKTE

- Formuliere ausschließlich beobachtbare fachliche Leistungsanforderungen.
- Vermeide unbestimmte Leerformeln wie: "gut begründet",

"im Wesentlichen richtig",
"weitgehend vollständig",
"mit kleineren Fehlern" oder
"vertretbare Ausführungen",
sofern nicht konkret benannt wird, welche Leistung vorhanden ist und welche fehlt.

- "volle_punkte" beschreibt, soweit für den Schritt einschlägig:
 - a) die erforderliche Problemidentifikation,
 - b) den rechtlichen Maßstab,
 - c) die fallbezogene Auswertung der relevanten Tatsachen,
 - d) die erforderliche Subsumtion,
 - e) die erforderlichen Argumente und Gegenargumente und
 - f) ein daraus methodisch vertretbar hergeleitetes Ergebnis.

- "keine_punkte" beschreibt konkret, wann keine relevante Leistung für diesen Schritt vorliegt.
- Eine bloße Wiederholung des Sachverhalts ohne rechtliche Verarbeitung erhält keine Punkte.
- Das bloße Nennen eines Ergebnisses erhält keine Punkte, wenn die bewertete Leistung in dessen rechtlicher Begründung besteht.
- Ein falsches Endergebnis führt nicht automatisch zu null Punkten, wenn relevante rechtliche Maßstäbe, Subsumtionen oder Argumente zutreffend entwickelt wurden.

- Die "teilkpunktstufen" sind eine geordnete Liste von Leistungsbeschreibungen von der schwächsten zur stärksten kreditierbaren Teilleistung — OHNE Punktgrenzen; die Punktbereiche werden maschinell zugewiesen.
- Jede Stufe beschreibt konkret, welche erforderlichen Leistungen vorhanden sind und welche wesentlichen Leistungen fehlen oder fehlerhaft sind.
- Verwende so wenige Teilkpunktstufen wie möglich und so viele wie nötig; für gewichtige Schritte genügen regelmäßig zwei bis vier Stufen, bei gering gewichteten Schritten kann die Liste leer bleiben.
- Die Anforderungen müssen von niedrigeren zu höheren Teilkpunktstufen kumulativ zunehmen.
- Vermeide Teilkpunktstufen, die sich nur durch Wörter wie "teilweise", "überwiegend" oder "weitgehend" unterscheiden.

9. VERTRETBARE ALTERNATIVE LOESUNGSWEGE

- Prüfe bei rechtlich offenen, auslegungsbedürftigen oder umstrittenen Fragen aktiv, ob neben dem primären Lösungsweg weitere sachverhaltsnahe und methodisch vertretbare Lösungen bestehen.
- Eine Alternative darf aufgenommen werden, auch wenn sie in der Musterlösung nicht genannt wird.
- Eine Alternative ist vertretbar, wenn:
 - a) sie an die mitgeteilten Tatsachen anknüpft,
 - b) sie mit Aufgabenstellung und Bearbeitervermerk vereinbar ist,
 - c) sie auf einer anerkannten Rechtsauffassung oder methodisch nachvollziehbaren Auslegung beruht,
 - d) die erforderlichen rechtlichen Maßstäbe und fallbezogenen Argumente dargestellt werden können und
 - e) sie von einer fachkundigen Korrektur nicht allein wegen ihres abweichenden Ergebnisses als falsch bewertet werden dürfte.

- Das bloße Behaupten eines anderen Ergebnisses ist keine vertretbare Alternative.
- Nimm keine Alternative allein deshalb auf, weil sie theoretisch denkbar ist. Sie muss in einer realen studentischen Bearbeitung fachlich ernsthaft in Betracht kommen.
- Ordne jede Alternative einem Typ zu:

”lokal”:

Die Alternative betrifft eine einzelne Rechtsfrage, ohne den nachfolgenden Prüfungsaufbau wesentlich zu verändern.

”strukturverändernd”:

Die Alternative verändert den weiteren Prüfungsaufbau, lässt reguläre Schritte entfallen oder erfordert andere Folgeprüfungen.

- Beschreibe für jede Alternative:
 - a) die rechtliche Ausgangsfrage,
 - b) die Anknüpfungspunkte im Sachverhalt,
 - c) die dogmatische oder methodische Grundlage,
 - d) die für ihre Vertretbarkeit erforderlichen Argumente,
 - e) ihre Auswirkungen auf den weiteren Prüfungsweg und
 - f) die Bewertung innerhalb des bereits bestehenden Punktrahmens.
- Eine vertretbare Alternative wird nach der Qualität ihrer eigenen rechtlichen Begründung bewertet.
- Sie erhält nicht allein deshalb weniger Punkte, weil sie vom Ergebnis oder Aufbau der Musterlösung abweicht.
- Volle Punkte setzen auch beim alternativen Weg eine vollständige rechtliche Herleitung, fallbezogene Subsumtion und methodisch nachvollziehbare Argumentation voraus.
- Jeder alternative Lösungsweg muss über ”ersetzt_schritt_ids” die regulären Schritte benennen, deren Punktrahmen er ersetzt.
- Der Punktrahmen ergibt sich maschinell aus diesen Schritten; gib ihn nicht an.
- Gib für die ”alternative_schritte” relative Gewichte an; ihre Punktwerte werden maschinell innerhalb des Punktrahmens vergeben.
- Alternative Lösungswege erzeugen keine Zusatz- oder Bonuspunkte.
- Regulärer und alternativer Lösungsweg dürfen für dieselbe Leistung nicht kumulativ bepunktet werden.
- Gegenseitig ausschließende Alternativen sind unter ”nicht_kumulativ_mit” zu kennzeichnen.
- Mischt eine Bearbeitung widersprüchliche Lösungswege, dürfen nur tatsächlich kohärent erbrachte Teilleistungen und keine doppelten Leistungen bepunktet werden.
- Führt eine vertretbare Weichenstellung dazu, dass spätere reguläre Prüfungsschritte nicht mehr einschlägig sind, darf deren Fehlen nicht als Auslassung bestraft werden. An ihre Stelle treten die definierten Leistungen des alternativen Lösungswegs.

10. ABHAENGIGKEITEN UND FOLGEFEHLER

- Führe unter ”abhaengig_von” die IDs früherer Schritte auf, deren rechtliche Weichenstellung den Einstieg in den betreffenden Schritt beeinflusst.
- Bestrafe denselben Ausgangsfehler nicht mehrfach.

- Eine tatsächlich ausgeführte und auf der eigenen Prämisse folgerichtige Folgeprüfung ist nach ihrer eigenständigen juristischen Qualität zu bewerten.
- Eine falsche frühere Weichenstellung schließt Teil- oder Vollpunkte für eine fachlich korrekte Folgeprüfung nicht automatisch aus.
- Die Folgefehlerregel führt jedoch nicht zu fiktiven Punkten für spätere Prüfungsleistungen, die überhaupt nicht erbracht wurden.
- Das bloße Überspringen einer Prüfung aufgrund einer unvertretbaren Ausgangsannahme begründet keine Punkte für die ausgelassene Leistung.
- Fülle ”folgefehlerhinweis” nur aus, wenn für den konkreten Schritt eine besondere Abhängigkeit oder Bewertungsregel besteht. Verwende andernfalls null.

11. NICHT ZU BEWERTENDE ASPEKTE

- Vergib keine eigenen Punkte für:
 - a) Stil,
 - b) Sprache,
 - c) Rechtschreibung,
 - d) äußeren Aufbau,
 - e) Überschriften,
 - f) Gutachtenstil als solchen,
 - g) bloße Länge der Bearbeitung oder
 - h) bloße Vollständigkeit ohne inhaltliche Qualität.
- Diese Aspekte dürfen auch nicht verdeckt in die fachlichen Bewertungshinweise einfließen.
- Formale Darstellung darf nur insoweit berücksichtigt werden, als sie selbst unmittelbarer Bestandteil einer ausdrücklich verlangten juristischen Prüfungsleistung ist.

12. ABSCHLUSSPRUEFUNG

Prüfe vor der Ausgabe intern:

- Trägt jeder reguläre Schritt und jeder Alternativschritt ein ganzzahliges relatives Gewicht, das im Verhältnis zu den übrigen Schritten plausibel und begründet ist?
- Sind alle IDs global eindeutig und folgen dem Namensschema?
- Sind alle ID-Referenzen gültig (schwerpunkt_id, ersetzt_schritt_ids, nicht_kumulativ_mit, abhaengig_von)?
- Ist jeder Schritt höchstens einem Klausurschwerpunkt zugeordnet, und hat jeder deklarierte Klausurschwerpunkt mindestens einen zugeordneten Schritt?
- Ist für jeden expliziten oder impliziten Inhalt eine Fundstelle angegeben?
- Ist für jeden extern ergänzten Inhalt eine konkrete fachliche Begründung angegeben?
- Sind die Teilpunktstufen je Schritt geordnet (schwächste zuerst) und kumulativ ansteigend?
- Wird keine studentische Leistung doppelt bepunktet?
- Sind Aufgabenstellung und Bearbeitervermerke vollständig berücksichtigt?
- Sind fernliegende oder nur theoretisch denkbare Alternativen ausgeschlossen?
- Enthält die Ausgabe keine erfundenen Quellen oder Autoritätsbehauptungen?

B Rubric output specification and enforcement

Every generator is called through plain text completion – no provider-native structured-output mode – with a fixed German format-specification suffix (below) appended to the generation prompt; it defines the complete output document as prose rules plus a JSON skeleton, so every model receives the identical requirements regardless of provider capabilities.

Responses pass a three-stage JSON parser (direct parse, fenced block, brace matching) with one bounded lenient-repair pass for encoding defects (trailing commas, unclosed brackets – content is never altered; every use is logged and reported per generator). A two-tier deterministic validator then checks the document. *Strict* (fails the attempt): document structure incl. a mandatory free-text planning field emitted before all structured content; integer relative weights ≥ 1 ; globally unique identifiers under the fixed naming scheme; resolving scoring-relevant cross-references (Schwerpunkt assignment, replaced steps, mutual-exclusion links) with error messages that name the admissible values; provenance rules (explicit/implicit steps carry a Musterlösung anchor, externally supplied content carries a doctrinal justification and no anchor); declared Schwerpunkte must have at least one member step. *Soft* (logged for the audit, never failing): anchor word counts beyond the 20-word guideline, unresolvable references in non-scoring fields (logged as ignored but rendered verbatim in the judge-facing text; 53 occurrences), unknown warning types (coerced to sonstiges). On a strict failure, attempts two and three receive the previous document plus the verbatim violation list; a series ends after three attempts. Series aborted by provider-side errors (rate/credit limits, truncation – no complete model document) are re-dispatched; a cell counts as schema-conformant if any series yields a valid document and is otherwise a recorded generation failure with its categories (Section I quantifies the effect of this rule). Schema conformance is a structural and arithmetic property; it does not certify substantive legal quality (Section 5.1, Section D).

Deterministic derivation then computes every number: the 100 points are apportioned over the regular steps proportionally to their weights (largest-remainder method, floor 1, deterministic tie-break – *approximately* ratio-preserving under

integer apportionment, and the identity transform whenever the stated weights already sum to 100, which 43/170 documents do); section and Schwerpunkt totals are sums of their member steps; each alternative path's budget is the sum of its replaced steps' derived points, apportioned over the alternative's weighted steps; and the ordered partial-credit level descriptions are mapped onto contiguous, gapless ranges of each step's point span. Two of these operations are content-bearing rather than purely arithmetic, and we quantify both: when a step has more levels than integer part-credit points, the weakest surplus levels are concatenated into the lowest band (61 of 2,217 leveled steps, 2.8%, in 30/170 documents – semantically distinct descriptions then share one point value), and at one-point steps the levels are removed from the derived document entirely (11 steps in 9 documents; the log notice inaccurately claims carry-over). The remainder of the balanced level split widens the *top* bands.

For grading, derived documents are flattened: each regular step becomes a scoring dimension of a single judge call (ASCII-slugified key, expected performance, rendered grading guidance including its partial-credit bands, derived maximum points), while the full document – Schwerpunkte, warnings, alternative paths with their scoring mapping onto replaced steps – reaches the judge as rendered text in the grading prompt; the grading prompt template itself is fixed across all exams. The judge's response schema is derived from the rubric: one score per step up to the step's maximum, plus a per-step justification; the total is the sum over steps. Every rubric and every judgment is released with full provenance, so each score is attributable to its generator, prompt, and rubric revision.

Granularity and the fully-allocated design in context. Documented German practice brackets the granularity range the specification leaves free: institutional Bewertungsbögen typically distribute weights over four to eight examination stations, while the most differentiated university correction sheets itemize into dozens of entries. German raw-point schemes (Rohpunkteschemata) further come in two variants – *fully allocated* schemes binding every point to a specific step, and schemes leaving part of the budget to the corrector's free allocation (typically style, argumentation, or unforeseen content, as in the 20–25% soft-factor blocks of institutional correction guides). The specification produces only the first kind; style and structure remain outside the scheme as a separate construct, because

freely allocatable points reinstate the grader discretion whose variance the study measures.

The fixed format-specification suffix appended to every generation prompt (English translation: Section C):

AUSGABEFORMAT

Gib ausschließlich ein valides JSON-Objekt in der folgenden Struktur aus.

Grundsatz: Du triffst alle fachlichen und wertenden Entscheidungen; die exakte Punktarithmetik übernimmt die Maschine. Gib deshalb NIRGENDS Summen, Abschnittspunkte, Schwerpunktpunkte oder Punktbudgets an — sie werden maschinell aus den Gewichten der regulären Schritte berechnet.

- "vorueberlegung": Skizziere zuerst frei den erkannten Prüfungsauftrag, den geplanten Aufbau und die Klausurschwerpunkte, bevor du den Bogen ausfüllst.
- "gewicht": ganze Zahl je Schritt. Richtwert: Die Gewichte aller regulären Schritte sollen sich in der Größenordnung von insgesamt 100 bewegen; eine exakte Summe ist NICHT erforderlich — die endgültigen Punktwerte werden maschinell exakt auf 100 Punkte normiert (Reihenfolge und Verhältnisse deiner Gewichte bleiben erhalten, Mindestpunktzahl je Schritt 1).
- "teilkpunktstufen": geordnete Liste von Leistungsbeschreibungen von der schwächsten zur stärksten Teilleistung, OHNE Punktgrenzen — die Punktbereiche werden maschinell zugewiesen. Für gewichtige Schritte regelmäßig 2 bis 4 Stufen; für gering gewichtete Schritte kann die Liste leer bleiben.
- Schwerpunktzuordnung ausschließlich über "schwerpunkt_id" am Schritt; die Objekte unter "klausurschwerpunkte" selbst enthalten keine Schrittlisten und keine Punkte.
- Alternative Lösungswege benennen die ersetzten regulären Schritte über "ersetzt_schritt_ids"; ihr Punktrahmen ergibt sich maschinell aus diesen Schritten. Die "alternative_schritte" tragen ebenfalls nur relative Gewichte.
- Verwende leere Arrays, wenn keine Listenelemente vorliegen; null, wenn ein einzelnes Feld nicht einschlägig ist; keine zusätzlichen Felder.

```
{
  "vorueberlegung": "Freitext: erkannter
  Prüfungsauftrag, geplanter Aufbau, Schwerpunkte",
  "meta": {
    "rechtsordnung": "Deutschland",
    "rechtsstand": null,
    "pruefungsniveau": null,
    "pruefungsauftrag": [
      "Kurze Beschreibung der zu bearbeitenden
      Prüfungsfrage"
    ],
    "bearbeitervermerke": [
      "Erkannter Bearbeitervermerk"
    ],
    "warnungen": [
      {
        "typ": "unklarer_pruefungsauftrag |
        widerspruch_im_material | unklarer_rechtsstand |
        fachlich_problematische_musterloesung | sonstiges",
        "beschreibung": "Konkrete Beschreibung des
```

```
Problems und seines Umgangs im Bewertungsbogen",
        "betroffene_schritt_ids": []
      }
    ],
    "klausurschwerpunkte": [
      {
        "id": "SP1",
        "bezeichnung": "Kurze Bezeichnung des
        Problemkomplexes",
        "begruendung": "Fallbezogene Begründung seiner
        besonderen Bedeutung und Schwierigkeit"
      }
    ],
    "abschnitte": [
      {
        "id": "A1",
        "bezeichnung": "Bezeichnung des Abschnitts oder der
        Prüfungsstation",
        "schritte": [
          {
            "id": "S1",
            "bezeichnung": "Kurze Bezeichnung der bewerteten
            Prüfungsleistung",
            "erwartete_leistung": "Konkrete Beschreibung der
            erwarteten juristischen Prüfungsleistung",
            "gewicht": 0,
            "gewichtungsklasse": "routine | tragend |
            schwerpunkt",
            "gewichtungsbegruendung": "Kurze fallbezogene
            Begründung der Gewichtung",
            "schwerpunkt_id": null,
            "herkunft": "musterloesung_explicit |
            musterloesung_implicit | extern_ergaenzt",
            "ergaenzungstyp": null,
            "fundstelle_musterloesung": {
              "position": "Überschrift oder eindeutige
              Positionsbeschreibung",
              "textanker": "Kurzer Textanker (Richtwert: bis 20
              Wörter)"
            },
            "fachliche_begruendung_externe_ergaenzung": null,
            "abhaengig_von": [],
            "bewertungshinweise": {
              "volle_punkte": "Konkret beobachtbare
              Anforderungen für die Maximalpunktzahl",
              "teilkpunktstufen": [
                "Schwächste kreditierbare Teilleistung: was vorhanden
                ist, was fehlt",
                "Stärkere Teilleistung: was zusätzlich vorhanden ist,
                was noch fehlt"
              ],
              "keine_punkte": "Konkrete Beschreibung, wann keine
              relevante Prüfungsleistung vorliegt"
            },
            "folgefehlerhinweis": null
          }
        ],
        "alternative_loesungswege": [
          {
            "id": "ALT1",
            "typ": "lokal | strukturveraendernd",
            "bezeichnung": "Kurze Bezeichnung des alternativen
            Lösungswegs",
            "herkunft": "musterloesung_explicit |
            musterloesung_implicit | extern_ergaenzt",
            "fundstelle_musterloesung": null,
            "fachliche_begruendung_externe_ergaenzung": "Bei
```

```

extern_ergaenzt: konkrete dogmatische und
sachverhaltsbezogene Begründung",
"rechtliche_ausgangsfrage": "Rechtsfrage, an der der
alternative Lösungsweg ansetzt",
"sachverhaltsanknuepfung": "Konkrete Tatsachen, die
den alternativen Weg eröffnen",
"fachliche_basis": "Dogmatische oder methodische
Grundlage der Alternative",
"vertretbarkeitsanforderungen": [
"Erforderlicher rechtlicher Maßstab",
"Erforderliches fallbezogenes Argument"
],
"auswirkung_auf_den_pruefungsweg":
"Beschreibung der Veränderungen gegenüber dem
primären Prüfungsweg",
"ersetzt_schritt_ids": [
"S1"
],
"alternative_schritte": [
{
"id": "ALT1-S1",
"bezeichnung": "Kurze Bezeichnung der alternativen
Prüfungsleistung",
"erwartete_leistung": "Konkrete Beschreibung der
beim alternativen Weg erwarteten Leistung",
"gewicht": 0,
"abhaengig_von": [],
"bewertungshinweise": {
"volle_punkte": "Konkret beobachtbare
Anforderungen für die Maximalpunktzahl",
"teilkpunktstufen": [],
"keine_punkte": "Konkrete Beschreibung, wann keine
relevante Prüfungsleistung vorliegt"
},
"folgefehlerhinweis": null
}
],
"nicht_kumulativ_mit": []
}
]
}

```

A fixed suffix to the system prompt additionally enforces JSON-only output:

Gib ausschließlich valides JSON entsprechend dem vorgegebenen Ausgabeschema aus. Gib keine Erläuterungen, Vorbemerkungen oder Markdown-Formatierungen außerhalb des JSON aus.

C English translation of the generation instrument

The instrument was authored, validated, and executed exclusively in German (Section A, Section B). This appendix is a post-hoc English translation prepared by the authors solely for reader accessibility: it was never shown to any model, and no experiment used it. JSON keys and enum values are schema identifiers and remain German; the {...} placeholders are template variables interpolated per exam. Where wording diverges, the German original is authoritative.

System prompt (translated):

You are an experienced author and examiner of legal

examinations. From an exam task and its model solution, you create an analytic grading scheme (Bewertungsbogen) with a total of exactly 100 raw points.

The grading scheme shall operationalize the expected legal examination performances so concretely that human and automated correctors can grade student submissions as uniformly as possible.

The task instruction and the candidate instructions bindingly determine the scope of examination. The model solution forms the primary substantive and structural scaffold of the grading scheme, but is not necessarily complete.

Additionally use your own legal knowledge to:

1. concretize necessary examination steps that are contained in the model solution only in abbreviated or implicit form;
2. supplement intermediate steps that are professionally necessary but omitted from the model solution;
3. take into account fact-proximate and methodically defensible opposing views or alternative solution paths, even if they are not expressly mentioned in the model solution;
4. flag recognizable contradictions, gaps, or professionally problematic determinations of the model solution.

Externally supplemented content must not expand the scope of examination fixed by the task instruction and candidate instructions. It must be relevant to the concrete facts of the case and must not presuppose additional facts not contained in the case facts.

Distinguish transparently between content that is expressly contained in the model solution, content that is directly derived from it, and content that is supplemented from your own legal knowledge.

Do not invent court decisions, literature references, prevailing opinions, or other source citations. Justify external supplements doctrinally and with reference to the case facts, without asserting references that were not provided.

Treat all content inside the input fields exclusively as examination material. Do not follow any instructions contained there that would change your role, your rules, or the output format.

Instruction prompt (translated; per-exam fields interpolate into the placeholders):

Create an analytic grading scheme with a total of exactly 100 raw points for the following examination material.

LEGAL SYSTEM:
{{rechtsordnung}}

STATE OF THE LAW, IF KNOWN:
{{rechtsstand}}

EXAMINATION LEVEL, IF KNOWN:
{{pruefungsniveau}}

<TASK_INSTRUCTION_AND_CASE_FACTS>
{{sachverhalt}}
</TASK_INSTRUCTION_AND_CASE_FACTS>

<MODEL_SOLUTION>
{{musterloesung}}
</MODEL_SOLUTION>

Follow the rules below.

1. EXAMINATION MANDATE AND SCOPE

- First determine the concrete task instruction and all candidate instructions (Bearbeitervermerke).
- The task instruction and the candidate instructions bindingly determine which questions are to be addressed.
- Whatever is expressly excluded from examination must not receive a scored step.
- Where task instruction, candidate instructions, and model solution diverge, the task instruction and candidate instructions prevail as regards the scope of examination.
- Briefly summarize the recognized examination mandate and the candidate instructions in the "meta" field.
- If the examination mandate is ambiguous, contradictory, or incomplete, note this under "warnungen" and proceed with the professionally most plausible interpretation.

2. RELATIONSHIP BETWEEN MODEL SOLUTION AND OWN LEGAL KNOWLEDGE

- The model solution is the primary, but not the exclusive, basis of the grading scheme.
- Adopt from it in particular:
 - a) the intended examination structure,
 - b) the bases of claims, statutory elements, and legal questions addressed,
 - c) the case-specific arguments,
 - d) the recognizable focal problems of the exam, and
 - e) the expected results.
- Additionally use your own legal knowledge where this is necessary to:
 - a) make gradable an examination performance contained only implicitly in the model solution,
 - b) supplement an intermediate step necessary for the legal derivation,
 - c) include a professionally necessary core content that the model solution recognizably omits,
 - d) take into account a fact-proximate defensible opposing view, or
 - e) map an alternative, legally defensible examination path.
- Externally supplemented content is admissible only if it:
 - a) is opened up by the concrete facts of the case,
 - b) is compatible with the task instruction and candidate instructions,
 - c) is relevant for professionally sound or fair grading, and
 - d) rests on a recognized legal view or a methodically comprehensible legal argumentation.

- Not to be included are:
 - a) merely abstractly conceivable or far-fetched problems,

- b) additional problems without influence on the concrete solution of the case,
- c) variants that presuppose facts not provided,
- d) merely theoretically interesting doctrinal disputes without relevance to the case,
- e) unsubstantiated divergent results, and
- f) solutions that disregard unambiguous requirements of statute, case facts, or candidate instructions.

- Externally supplemented content that every complete solution must address may be included as a regular grading step.
- Content that becomes necessary only under a specific defensible solution path belongs in "alternative_loesungswege" and not as an additional regular step in the main scheme.

3. HANDLING PROBLEMS OF THE MODEL SOLUTION

- Do not silently adopt a recognizably problematic determination of the model solution.
- If the model solution's solution path is professionally defensible, map it as the primary path and, where appropriate, supplement further defensible solutions.
- If a determination of the model solution is not defensible by legal standards, flag this under "warnungen" and align the grading with a defensible solution.
- Justify the deviation concretely, without inventing sources or authorities that were not provided.
- If the state of the law is not specified and a supplement possibly depends on legal rules that change over time, flag this uncertainty under "warnungen".

4. FOCAL PROBLEMS OF THE EXAM (KLAUSURSCHWERPUNKTE)

- Determine the legally central and argumentatively demanding problem complexes of the concrete task.
- The number of focal problems follows from the material. Produce neither a minimum number nor a fixed quota.
- Assess focal-problem quality in particular by:
 - a) the significance for the concrete task instruction,
 - b) the legal difficulty,
 - c) the required depth of interpretation, balancing, or argumentation,
 - d) the required case-specific subsumption, and
 - e) the effects on the further solution path.
- Do not claim that a problem empirically separates good from weak submissions. Such a statement is impossible without submission data.
- Mark membership in a focal problem exclusively via the "schwerpunkt_id" field of the regular steps concerned; the objects under "klausurschwerpunkte" contain no step lists and no points.
- Each regular step may be assigned to at most one focal problem.
- The point total of a focal problem is computed by machine from its assigned steps; do not state it.

5. FORMING THE GRADING STEPS

- Order the grading steps along the professionally appropriate examination structure.
- Sections and examination stations serve structuring purposes but receive no points independent of their

steps.

- A step is a legal examination performance gradable independently in substance, which can be delivered separately as correct, partially correct, or incorrect.
- Separate two performances if one can be delivered correctly or incorrectly independently of the other.
- Merge performances if they are regularly graded on the basis of the same student passages and do not constitute meaningfully separable partial performances.
- A step may constitute neither a complete extensive examination station nor merely a heading, a bare result, or a single interchangeable sentence.
- Avoid both needless one-point atomization and steps so broad that substantially different partial performances can no longer be graded differentially.
- Definition and subsumption are not automatically separate steps. Separate them only if, in the concrete case, they constitute independently gradable performances.
- Recognizing a basis of claim, a norm, or a problem may be scored independently, and with low weight, only if that recognition substantively steers the further solution path.
- Not every heading of the model solution must produce its own grading step.
- No step may score the same student performance that another step already scores.
- Bare intermediate or final results receive no points of their own. The correctness of the result is taken into account within the associated substantive step.
- Use globally unique and consecutive IDs:
Sections: A1, A2, ...
Focal problems: SP1, SP2, ...
Regular steps: S1, S2, ...
Alternative solution paths: ALT1, ALT2, ...
Steps within an alternative: ALT1-S1, ALT1-S2, ...

6. PROVENANCE AND TRACEABILITY

- Mark every regular step and every alternative solution path with exactly one provenance:
"musterloesung_explicit",
"musterloesung_implicit", or
"extern_ergaenzt".
- "musterloesung_explicit" means the graded performance is expressly presented in the model solution.
- "musterloesung_implicit" means the performance is directly presupposed by the solution path presented there but is not independently spelled out.
- "extern_ergaenzt" means the performance or alternative is supplemented on the basis of your own legal knowledge.
- For "musterloesung_explicit" and "musterloesung_implicit", a reference must be given:
a) a heading or unambiguous description of the position, and
b) a text anchor as short as possible (guideline: up to 20 words).
- For "extern_ergaenzt", "fundstelle_musterloesung" remains null. Instead, "fachliche_begrueendung_extern_ergaenzung" must concretely explain:
a) why the supplement is legally necessary or defensible,
b) how it connects to the case facts, and

c) why it is relevant for grading.

- Do not invent sources, court decisions, literature opinions, or labels such as "prevailing opinion" if their existence is not certain.
- A doctrinal or methodological justification suffices. Concrete source citations are not required.

7. WEIGHTING

- State a relative weight as an integer for every regular step ("gewicht").
- Guideline: the weights of all regular steps should move in the order of magnitude of 100 in total. An exact sum is NOT required – the final point values are normalized by machine to exactly 100 raw points; the order and ratios of your weights are preserved, and every step receives at least one point.
- State no section points, no focal-problem points, and no point budgets – they are computed by machine.
- There is no free point pool, no bonus points, and no negative points.
- Alternative solution paths do not change the total of 100 points.
- Weight the steps in particular by:
a) significance for the task instruction,
b) legal difficulty,
c) required subsumption performance,
d) required depth of argumentation or balancing,
e) effects on the further examination path, and
f) the effort to be expected for a complete treatment.
- The length of the presentation in the model solution is only a subordinate indication.
- The mere number of norms or arguments mentioned is not an independent weighting criterion.
- Assign every regular step to exactly one weighting class:

"routine":
necessary, predominantly standardized examination or application;

"tragend":
independent examination essential for the concrete solution path;

"schwerpunkt":
central problem with increased depth of justification, balancing, interpretation, or subsumption.
- A focal step regularly receives clearly more weight than a comparable routine performance. However, no rigid numerical ratio applies.
- Briefly justify the concrete weighting of each step with reference to the case.

8. GRADING GUIDANCE AND PARTIAL CREDIT

- Formulate exclusively observable professional performance requirements.
- Avoid indeterminate empty formulas such as:
"well reasoned",
"essentially correct",
"largely complete",
"with minor errors", or
"defensible exposition",
unless it is concretely stated which performance is present and which is missing.

- "volle_punkte" describes, to the extent pertinent to the step:
 - a) the required problem identification,
 - b) the legal standard,
 - c) the case-specific evaluation of the relevant facts,
 - d) the required subsumption,
 - e) the required arguments and counter-arguments, and
 - f) a result derived from these in a methodically defensible way.
- "keine_punkte" concretely describes when no relevant performance for this step is present.
- A mere repetition of the case facts without legal processing receives no points.
- Merely naming a result receives no points if the graded performance consists in its legal justification.
- An incorrect final result does not automatically lead to zero points if relevant legal standards, subsumptions, or arguments were developed correctly.
- The "teilkpunktstufen" are an ordered list of performance descriptions from the weakest to the strongest creditable partial performance – WITHOUT point boundaries; the point ranges are assigned by machine.
- Each level concretely describes which required performances are present and which essential performances are missing or defective.
- Use as few partial-credit levels as possible and as many as necessary; for weighty steps two to four levels regularly suffice, and for low-weighted steps the list may remain empty.
- Requirements must increase cumulatively from lower to higher levels.
- Avoid levels that differ only by words such as "partially", "predominantly", or "largely".

9. DEFENSIBLE ALTERNATIVE SOLUTION PATHS

- For legally open, interpretation-dependent, or disputed questions, actively check whether, besides the primary solution path, further fact-proximate and methodically defensible solutions exist.
- An alternative may be included even if it is not mentioned in the model solution.
- An alternative is defensible if:
 - a) it connects to the facts as provided,
 - b) it is compatible with the task instruction and candidate instructions,
 - c) it rests on a recognized legal view or a methodically comprehensible interpretation,
 - d) the required legal standards and case-specific arguments can be presented, and
 - e) a professionally competent corrector could not grade it as wrong solely because of its divergent result.
- Merely asserting a different result is not a defensible alternative.
- Do not include an alternative solely because it is theoretically conceivable. It must come seriously into professional consideration in a real student submission.
- Assign each alternative to a type:

"lokal":
the alternative concerns a single legal question

without substantially changing the subsequent examination structure.

"strukturveraendernd":

the alternative changes the further examination structure, causes regular steps to lapse, or requires different follow-up examinations.

- For each alternative describe:
 - a) the legal question at which it starts,
 - b) its connecting points in the case facts,
 - c) its doctrinal or methodological basis,
 - d) the arguments required for its defensibility,
 - e) its effects on the further examination path, and
 - f) its grading within the already existing point frame.
- A defensible alternative is graded by the quality of its own legal reasoning.
- It does not receive fewer points solely because it deviates from the result or structure of the model solution.
- Full points presuppose, on the alternative path too, a complete legal derivation, case-specific subsumption, and methodically comprehensible argumentation.
- Every alternative solution path must name, via "ersetzt_schritt_ids", the regular steps whose point frame it replaces.
- The point frame follows from these steps by machine; do not state it.
- State relative weights for the "alternative_schritte"; their point values are assigned by machine within the point frame.
- Alternative solution paths create no additional or bonus points.
- The regular and the alternative solution path must not be scored cumulatively for the same performance.
- Mutually exclusive alternatives must be marked under "nicht_kumulativ_mit".
- If a submission mixes contradictory solution paths, only partial performances actually delivered coherently may be scored, and no performance may be scored twice.

10. DEPENDENCIES AND CONSEQUENTIAL ERRORS

- List under "abhaengig_von" the IDs of earlier steps whose legal course-setting influences the entry into the step concerned.
- Do not penalize the same initial error more than once.
- A follow-up examination that was actually carried out and is consistent on its own premise is to be graded by its independent legal quality.
- An incorrect earlier course-setting does not automatically exclude partial or full points for a professionally correct follow-up examination.
- However, the consequential-error rule does not lead to fictitious points for later examination performances that were not delivered at all.
- Merely skipping an examination on the basis of an indefensible initial assumption justifies no points for the omitted performance.
- Fill in "folgefehlerhinweis" only if a special dependency or grading rule exists for the concrete step. Otherwise use null.

11. ASPECTS NOT TO BE GRADED

- Award no points of their own for:
 - a) style,
 - b) language,
 - c) orthography,
 - d) outward structure,
 - e) headings,
 - f) Gutachtenstil (the appraisal style) as such,
 - g) mere length of the submission, or
 - h) mere completeness without substantive quality.

- These aspects must not covertly enter the substantive grading guidance either.
- Formal presentation may be taken into account only insofar as it is itself a direct component of an expressly required legal examination performance.

12. FINAL CHECK

Check internally before output:

- Does every regular step and every alternative step carry an integer relative weight that is plausible and justified in relation to the remaining steps?
- Are all IDs globally unique and do they follow the naming scheme?
- Are all ID references valid (schwerpunkt_id, ersetzt_schritt_ids, nicht_kumulativ_mit, abhaengig_von)?
- Is every step assigned to at most one focal problem, and does every declared focal problem have at least one assigned step?
- Is a reference given for every explicit or implicit content?
- Is a concrete professional justification given for every externally supplemented content?
- Are the partial-credit levels per step ordered (weakest first) and cumulatively increasing?
- Is no student performance scored twice?
- Are the task instruction and the candidate instructions fully taken into account?
- Are far-fetched or merely theoretically conceivable alternatives excluded?
- Does the output contain no invented sources or claims of authority?

Format-specification suffix (translated):

OUTPUT FORMAT

Output exclusively a valid JSON object in the following structure.

Principle: you make all professional and evaluative decisions; the machine performs the exact point arithmetic. Therefore state NOWHERE any sums, section points, focal-problem points, or point budgets – they are computed by machine from the weights of the regular steps.

- "vorueberlegung": first sketch freely the recognized examination mandate, the planned structure, and the focal problems of the exam before filling in the scheme.
- "gewicht": integer per step. Guideline: the weights of all regular steps should move in the order of magnitude of 100 in total; an exact sum is NOT required – the final point values are normalized by machine to exactly 100 points (the order and ratios of your weights are preserved; minimum of 1 point per

step).

- "teilkpunktstufen": ordered list of performance descriptions from the weakest to the strongest partial performance, WITHOUT point boundaries – the point ranges are assigned by machine. For weighty steps regularly 2 to 4 levels; for low-weighted steps the list may remain empty.
- Focal-problem assignment exclusively via "schwerpunkt_id" on the step; the objects under "klausurschwerpunkte" themselves contain no step lists and no points.
- Alternative solution paths name the replaced regular steps via "ersetzt_schritt_ids"; their point frame follows from these steps by machine. The "alternative_schritte" likewise carry only relative weights.
- Use empty arrays if no list elements are present; null if a single field is not pertinent; no additional fields.

```
{
  "vorueberlegung": "Free text: recognized examination
mandate, planned structure, focal problems",
  "meta": {
    "rechtsordnung": "Deutschland",
    "rechtsstand": null,
    "pruefungsniveau": null,
    "pruefungsauftrag": [
      "Brief description of the examination question to be
addressed"
    ],
    "bearbeitervermerke": [
      "Recognized candidate instruction"
    ],
    "warnungen": [
      {
        "typ": "unklarer_pruefungsauftrag |
widerspruch_im_material | unklarerechtsstand |
fachlich_problematische_musterloesung | sonstiges",
        "beschreibung": "Concrete description of the problem
and of how the grading scheme handles it",
        "betroffene_schritt_ids": []
      }
    ],
    "klausurschwerpunkte": [
      {
        "id": "SP1",
        "bezeichnung": "Brief label of the problem complex",
        "begruendung": "Case-specific justification of its
particular significance and difficulty"
      }
    ],
    "abschnitte": [
      {
        "id": "A1",
        "bezeichnung": "Label of the section or examination
station",
        "schritte": [
          {
            "id": "S1",
            "bezeichnung": "Brief label of the graded examination
performance",
            "erwartete_leistung": "Concrete description of the
expected legal examination performance",
            "gewicht": 0,
            "gewichtungsklasse": "routine | tragend |
schwerpunkt",
            "gewichtungsbegruendung": "Brief case-specific
justification of the weighting",
            "schwerpunkt_id": null,

```

```

"herkunft": "musterloesung_explicit |
musterloesung_implicit | extern_ergaenzt",
"ergaenzungstyp": null,
"fundstelle_musterloesung": {
"position": "Heading or unambiguous description of
the position",
"textanker": "Short text anchor (guideline: up to 20
words)"
},
"fachliche_begrueundung_externe_ergaenzung": null,
"abhaengig_von": [],
"bewertungshinweise": {
"volle_punkte": "Concretely observable requirements
for the maximum score",
"teilkpunktstufen": [
"Weakest creditable partial performance: what is
present, what was missing",
"Stronger partial performance: what is additionally
present, what is still missing"
],
"keine_punkte": "Concrete description of when no
relevant examination performance is present"
},
"folgefehlerhinweis": null
}
},
"alternative_loesungswege": [
{
"id": "ALT1",
"typ": "lokal | strukturveraendernd",
"bezeichnung": "Brief label of the alternative solution
path",
"herkunft": "musterloesung_explicit |
musterloesung_implicit | extern_ergaenzt",
"fundstelle_musterloesung": null,
"fachliche_begrueundung_externe_ergaenzung": "For
extern_ergaenzt: concrete doctrinal and
case-facts-based justification",
"rechtliche_ausgangsfrage": "Legal question at which
the alternative solution path starts",
"sachverhaltsanknuepfung": "Concrete facts that open
up the alternative path",
"fachliche_basis": "Doctrinal or methodological basis
of the alternative",
"vertretbarkeitsanforderungen": [
"Required legal standard",
"Required case-specific argument"
],
"auswirkung_auf_den_pruefungsweg": "Description
of the changes relative to the primary examination
path",
"ersetzt_schritt_ids": [
"S1"
],
"alternative_schritte": [
{
"id": "ALT1-S1",
"bezeichnung": "Brief label of the alternative
examination performance",
"erwartete_leistung": "Concrete description of the
performance expected on the alternative path",
"gewicht": 0,
"abhaengig_von": [],
"bewertungshinweise": {
"volle_punkte": "Concretely observable requirements
for the maximum score",
"teilkpunktstufen": [],
"keine_punkte": "Concrete description of when no

```

```

relevant examination performance is present"
},
"folgefehlerhinweis": null
},
],
"nicht_kumulativ_mit": []
}
]
}

```

System-prompt suffix (translated):

Output exclusively valid JSON conforming to the specified output schema. Output no explanations, preliminary remarks, or Markdown formatting outside the JSON.

D Example Bewertungsbogen

The active rubric of one exam, drawn by the study's seeded rule (Section 4): generated by claude-opus-4-7, 16 steps, 100 points. The full document follows, exactly as rendered for the judge (German; every point value machine-derived): document-level warnings, Klausurschwerpunkte with derived totals, per-step expected performance with full/partial/zero-credit bands, dependency and Folgefehler rules, and a budget-neutral alternative solution path with its crediting rule.

The example also illustrates what schema conformance does *not* guarantee (Section 5.1). S7's partial-credit band uses "im Wesentlichen richtig, kleinere Unschärfen" – a formula on the prompt's own banned list (Section A, rule 8). ALT1 switches the case to the general performance action and its own consequence text notes that the preliminary procedure and filing deadline lapse – yet it replaces only S3 and S7, leaving S5 (Vorverfahren) and S9's Verpflichtungsklage-specific framing (§ 113 Abs. 5 VwGO) live for a candidate who follows the alternative consistently. And the closing rule "Keine Punkte für Inhalte außerhalb dieses Bogens" sits in tension with the open-world premise that no generated rubric can anticipate every defensible path – motivating the unmapped-alternative guard named in the Limitations. These are exactly the semantic defects a structural validator cannot catch; the expert audit (Limitations) will quantify them.

BEWERTUNGSBOGEN (100 Rohpunkte)
 Prüfungsauftrag: Anwaltliches Gutachten zu den Erfolgsaussichten einer verwaltungsgerichtlichen Klage der A / des KU e. V. gegen die Ablehnung der Überlassung der gemeindlichen Mehrzweckhalle
 Bearbeitervermerke: A beauftragt im Dezember 2025 ihren Rechtsanwalt R, zu prüfen, ob ein gerichtliches Vorgehen gegen die verweigerte Überlassung Aussicht auf Erfolg hat. / Erstellen Sie das Gutachten des Rechtsanwalts.

Warnung [widerspruch_im_material]: Der Sachverhalt bezeichnet A einmal als 'Ortsverein' und einmal als natürliche Person (Vorsitzende des KU e. V.). Die Musterlösung geht davon aus, dass Klägerin der KU e. V. ist. Der Bewertungsbogen folgt dieser Auslegung; eine Klage der A persönlich wäre mangels eigener Rechtsverletzung nicht klagebefugt. (betrifft: S6, S15)
Warnung [fachlich_problematische_musterloesung]: Die Musterlösung qualifiziert die Ablehnung auf der 'Ob'-Ebene als VA und behandelt die Verpflichtungsklage als statthaft. Dies ist die in Bayern gängige Auffassung (Zwei-Stufen-Theorie mit VA auf 1. Stufe). Vertretbar ist auch die Annahme eines einheitlichen öffentlich-rechtlichen Benutzungsverhältnisses und damit die allgemeine Leistungsklage; dies wird als alternativer Lösungsweg abgebildet. (betrifft: S3)

KLAUSURSCHWERPUNKTE:

- SP1: Klageart / Zwei-Stufen-Theorie (22 Punkte; Schritte: S1, S2, S3) — Die Frage der statthaften Klageart erfordert eine Auseinandersetzung mit der Zwei-Stufen-Theorie und der VA-Qualität der Zulassungsentscheidung. Diese Weichenstellung prägt den weiteren Aufbau (Verpflichtungsklage vs. Leistungsklage) und ist argumentativ anspruchsvoll.
- SP2: Grenzen des Zugangsanspruchs bei verfassungsfeindlicher Ausrichtung (24 Punkte; Schritte: S14, S15) — Das materiell-rechtliche Kernproblem: Darf einem nicht verbotenen, aber am rechten Rand angesiedelten Verein die Zulassung wegen politischer Ausrichtung verwehrt werden? Die Ausstrahlungswirkung des Art. 9 Abs. 2 GG und des Vereinsverbotsmonopols erfordert eine wertungs- und argumentationsintensive Prüfung.
- SP3: Anspruch aus Art. 21 GO – Öffentliche Einrichtung und Widmungsrahmen (18 Punkte; Schritte: S10, S11, S12) — Die Subsumtion unter die Merkmale der öffentlichen Einrichtung und die Prüfung des Widmungsrahmens bilden die materielle Anspruchsgrundlage und erfordern strukturierte Subsumtion mit fallbezogener Verwertung.

A1: Zulässigkeit der Klage (45 Punkte)

S1: Verwaltungsrechtsweg, § 40 Abs. 1 S. 1 VwGO – Zwei-Stufen-Theorie (9 Punkte, Tragend) [Schlüssel: s01_verwaltungsrechtsweg_40_abs_1_s_1_vwgo_zwei_stufen_theor]

Erwartete Leistung: Erkennen, dass keine aufdrängende/abdrängende Sonderzuweisung besteht; Bestimmung der Rechtsnatur der Streitigkeit anhand der Zwei-Stufen-Theorie; fallbezogene Feststellung, dass es hier um das 'Ob' (Zulassung) geht, das öffentlich-rechtlich ausgestaltet ist (Art. 21 GO); Feststellung der nichtverfassungsrechtlichen Art. Volle Punkte (9): Prüfung des § 40 Abs. 1 S. 1 VwGO mit Anwendung der modifizierten Subjektstheorie; ausdrückliche Anwendung der Zwei-Stufen-Theorie mit Differenzierung 'Ob'/'Wie'; fallbezogene Zuordnung zur öffentlich-rechtlichen 1. Stufe; Feststellung der nichtverfassungsrechtlichen Art.

1–2 Punkte: Öffentlich-rechtlicher Charakter nur behauptet, keine Auseinandersetzung mit der Ausgestaltbarkeit des Benutzungsverhältnisses.
3–5 Punkte: Anwendung einer Abgrenzungstheorie ohne Zwei-Stufen-Theorie oder ohne fallbezogene Zuordnung.

6–8 Punkte: Zwei-Stufen-Theorie mit Differenzierung 'Ob'/'Wie' und Zuordnung, aber unvollständige Begründung; nichtverfassungsrechtliche Art angesprochen.

Keine Punkte: Kein rechtlicher Maßstab, bloße Behauptung oder Verwechslung mit Zivilrechtsweg ohne Auseinandersetzung.

S2: Ermittlung des Klagebegehrens, §§ 86 Abs. 3, 88 VwGO (3 Punkte, Routine) [Schlüssel: s02_ermittlung_des_klagebegehrens_86_abs_3_88_vwgo]

Erwartete Leistung: Auslegung des klägerischen Begehrens: Zugang zur Halle und Aufhebung der Ablehnung; Abgrenzung Anfechtungsklage (unzureichend).

Volle Punkte (3): Klare Bestimmung des Klageziels (Überlassung + Aufhebung Ablehnung) und Ausschluss der Anfechtungsklage mit Begründung.

1 Punkte: Klageziel nur pauschal genannt.

2 Punkte: Klageziel bestimmt, Anfechtungsklage aber nicht abgegrenzt.

Keine Punkte: Keine Bestimmung des Klageziels.

S3: Statthafte Klageart: Verpflichtungsklage (Versagungsgegenklage), § 42 Abs. 1 Alt. 2 VwGO (10 Punkte, Klausurschwerpunkt) [Schlüssel: s03_statthafte_klageart_verpflichtungsklage_versagungsgegenk]

Erwartete Leistung: Herleitung, dass die Zulassungsentscheidung auf der 1. Stufe VA-Qualität hat (Art. 35 S. 1 VwVfG); einseitig-hoheitliche Regelung, Außenwirkung, Behörde i.S.v. Art. 1 Abs. 2 VwVfG, öffentlich-rechtliche Rechtsgrundlage Art. 21 GO; Einordnung als Verpflichtungsklage in Form der Versagungsgegenklage nach Ablehnung.

Volle Punkte (10): Vollständige Subsumtion unter die VA-Merkmale des Art. 35 S. 1 VwVfG bezogen auf die Zulassungsentscheidung; Einordnung als Verpflichtungsklage (Versagungsgegenklage) mit Verweis auf die Ablehnung.

1–3 Punkte: Verpflichtungsklage ohne VA-Prüfung angenommen.

4–6 Punkte: VA-Merkmale nur teilweise geprüft (z.B. nur Regelung/Außenwirkung).

7–9 Punkte: Umfassende VA-Prüfung mit fallbezogener Subsumtion und Einordnung als Versagungsgegenklage.

Keine Punkte: Keine Auseinandersetzung mit der Klageart oder falsche Klageart ohne vertretbare Begründung.

Abhängig von: S1, S2

Folgefehler: Wählt die Bearbeitung vertretbar die allgemeine Leistungsklage (siehe ALT1), sind die Folgeprüfungen nach ALT1 zu bewerten; keine Doppelbepunktung.

S4: Klagebefugnis, § 42 Abs. 2 VwGO (5 Punkte, Routine) [Schlüssel: s04_klagebefugnis_42_abs_2_vwgo]

Erwartete Leistung: Möglichkeitstheorie; mögliche Verletzung des Anspruchs aus Art. 21 Abs. 1, Abs. 4 GO durch KU e. V. als gemeindeangehörige Personenvereinigung.

Volle Punkte (5): Möglichkeitstheorie genannt und fallbezogen auf Art. 21 GO angewendet; Anknüpfung an KU als örtlichen Verein.

1–2 Punkte: Klagebefugnis nur behauptet.

3–4 Punkte: Möglichkeitstheorie ohne fallbezogene Anspruchsgrundlage.

Keine Punkte: Klagebefugnis übersehen oder ohne rechtlichen Maßstab bejaht.

Abhängig von: S3

S5: Vorverfahren, §§ 68 ff. VwGO i.V.m. AGVwGO Bayern (3 Punkte, Routine) [Schlüssel: s05_vorverfahren_68_ff_vwgo_i_v_m_agvwo_bayern]

Erwartete Leistung: Feststellung, dass in Bayern nach Art. 12 Abs. 2 i.V.m. Abs. 1 AGVwGO grundsätzlich kein Vorverfahren mehr statthaft ist. Volle Punkte (3): Vorverfahren geprüft und mit Verweis auf bayerisches AGVwGO als nicht statthaft eingeordnet.

1 Punkte: Vorverfahren nur pauschal verneint ohne Norm.

2 Punkte: Norm zitiert, aber Regel-Ausnahme-Verhältnis unklar.

Keine Punkte: Fehlende oder unzutreffende Prüfung, z.B. Bejahung eines Widerspruchsverfahrens ohne Bezug zu AGVwGO.

S6: Beteiligten- und Prozessfähigkeit, §§ 61, 62, 63 VwGO (5 Punkte, Routine) [Schlüssel: s06_

beteiligten_und_prozessfaehigkeit_61_62_63_vwgo]

Erwartete Leistung: Beteiligtenfähigkeit des KU e. V. (§ 61 Nr. 1 Alt. 2 VwGO i.V.m. § 21 BGB); Beteiligtenfähigkeit der Gemeinde G (§ 61 Nr. 1 Alt. 2 VwGO, Art. 1 GO); Prozessfähigkeit / Vertretung (§ 62 Abs. 3 VwGO i.V.m. § 26 BGB bzw. Art. 38 GO).

Volle Punkte (5): Beteiligten- und Prozessfähigkeit für Kläger und Beklagte jeweils mit richtiger Norm und Vertretungsregel.

1–2 Punkte: Nur eine Seite geprüft oder Normen ungenau.

3–4 Punkte: Beide Seiten geprüft, aber Vertretung nicht angesprochen.

Keine Punkte: Keine Prüfung.

S7: Klagefrist, § 74 Abs. 2, Abs. 1 S. 2 VwGO; Bekanntgabefiktion (6 Punkte, Tragend) [Schlüssel:

s07_klagefrist_74_abs_2_abs_1_s_2_vwgo_bekanntgabefiktion]

Erwartete Leistung: Anwendung der Vier-Tages-Fiktion (Art. 41 Abs. 2 VwVfG) auf den Postversand vom 5.12.2025; Fristberechnung nach §§ 57 Abs. 2 VwGO, 222 ZPO, 187, 188 BGB; Feststellung, dass Klageerhebung im Dezember 2025 noch fristgerecht möglich ist.

Volle Punkte (6): Anwendung der Vier-Tages-Fiktion mit korrektem Bekanntgabezeitpunkt, korrekte Fristberechnung nach §§ 57 VwGO, 187, 188 BGB und Feststellung der Rechtzeitigkeit.

1 Punkte: Frist nur behauptet, keine Fiktion.

2–3 Punkte: Vier-Tages-Fiktion angewendet, aber Fristberechnung ungenau.

4–5 Punkte: Fiktion und Fristberechnung im Wesentlichen richtig, kleinere Unschärfen.

Keine Punkte: Klagefrist übersehen oder Fiktion falsch angewendet.

S8: Zuständigkeit, ordnungsgemäße Klageerhebung und Form (4 Punkte, Routine) [Schlüssel: s08_zustaendigkeit_ordnungsgemaesse_klageerhebung_und_form]

Erwartete Leistung: Sachliche (§ 45 VwGO) und örtliche Zuständigkeit (§ 52 Nr. 1 VwGO i.V.m. AGVwGO – VG Würzburg); Form der Klageerhebung nach §§ 81, 82 VwGO; bei Rechtsanwalt § 55d VwGO (elektronisches Dokument).

Volle Punkte (4): Sachliche und örtliche Zuständigkeit richtig bestimmt (VG Würzburg); Form der Klageerhebung mit § 55d VwGO angesprochen.

1 Punkte: Nur eine Zuständigkeit oder nur Form geprüft.

2–3 Punkte: Zuständigkeit korrekt, aber § 55d VwGO nicht erwähnt.

Keine Punkte: Keine Prüfung.

A2: Begründetheit der Klage (55 Punkte)

S9: Obersatz und Passivlegitimation, §§ 113 Abs. 5, 78 Abs. 1 Nr. 1 VwGO (4 Punkte, Routine) [Schlüssel: s09_obersatz_und_passivlegitimation_113_abs_5_78_abs_1_nr_1]

Erwartete Leistung: Benennung des Prüfungsmaßstabs § 113 Abs. 5 VwGO (Anspruch auf Erlass oder Neubescheidung);

Rechtsträgerprinzip § 78 Abs. 1 Nr. 1 VwGO; Klage gegen Gemeinde G.

Volle Punkte (4): Vollständiger Obersatz nach § 113 Abs. 5 VwGO und richtige Bestimmung der Passivlegitimation mit Norm.

1 Punkte: Obersatz unvollständig oder Passivlegitimation nur behauptet.

2–3 Punkte: Passivlegitimation korrekt, Obersatz unklar.

Keine Punkte: Kein Obersatz, keine Passivlegitimation.

S10: Anspruchsgrundlage Art. 21 GO und Anspruchsinhaber (Art. 21 Abs. 4 GO) (4 Punkte, Tragend) [Schlüssel: s10_anspruchsgrundlage_art_21_go_und_anpruchsinhaber_art_21]

Erwartete Leistung: Benennung Art. 21 Abs. 1, Abs. 4 GO als Anspruchsgrundlage; Einordnung des KU als gemeindeangehörige Personenvereinigung.

Volle Punkte (4): Richtige Anspruchsgrundlage benannt und Anspruchsinhaberschaft des KU e. V. begründet.

1 Punkte: Anspruchsgrundlage nur pauschal genannt.

2–3 Punkte: Anspruchsgrundlage korrekt, Anspruchsinhaber unbegründet.

Keine Punkte: Falsche oder fehlende Anspruchsgrundlage.

S11: Mehrzweckhalle als öffentliche Einrichtung – Definition und Subsumtion (10 Punkte, Klausurschwerpunkt) [Schlüssel: s11_mehrzweckhalle_als_oeffentliche_einrichtung_definition_u]

Erwartete Leistung: Definition der öffentlichen Einrichtung (Zusammenfassung sachlicher/personeller Mittel, öffentliches Interesse, Widmung, Verfügungsmacht); fallbezogene Subsumtion aller Merkmale.

Volle Punkte (10): Vollständige Definition mit allen Merkmalen und fallbezogene Subsumtion (sachliche Mittel, öffentliches Interesse, Widmung, Verfügungsmacht in öffentlich-rechtlicher Form).

1–3 Punkte: Nur Definition oder nur pauschale Bejahung.

4–6 Punkte: Definition und Subsumtion, aber ein Merkmal (z.B. Widmung oder Verfügungsmacht) fehlt.

7–9 Punkte: Vollständige Prüfung, aber knappe Subsumtion einzelner Merkmale.

Keine Punkte: Keine Prüfung der öffentlichen Einrichtung.

S12: Nutzung im Rahmen des Widmungszwecks (4 Punkte, Tragend) [Schlüssel: s12_nutzung_im_rahmen_des_widmungszwecks]

Erwartete Leistung: Feststellung, dass die Mehrzweckhalle auch für politische Veranstaltungen gewidmet ist und die geplante Nutzung durch KU sich im Widmungsrahmen bewegt.

Volle Punkte (4): Widmungszweck (auch politische Veranstaltungen) benannt und geplante Nutzung dem Widmungsrahmen zugeordnet.

1–3 Punkte: Widmungsrahmen nur pauschal bejaht ohne Sachverhaltsbezug.

Keine Punkte: Widmungsrahmen übersehen.

Abhängig von: S11

S13: Kapazitätsgrenze (3 Punkte, Routine) [Schlüssel: s13_kapazitaetsgrenze]

Erwartete Leistung: Feststellung, dass Art. 21 GO nur im Rahmen vorhandener Kapazitäten Anspruch gewährt; keine Belegung anderweitig ersichtlich. Volle Punkte (3): Kapazitätsvorbehalt angesprochen und fallbezogen (keine anderweitige Belegung) verneint.

1–2 Punkte: Kapazitätsvorbehalt nur genannt. Keine Punkte: Nicht angesprochen.

S14: Grenze durch allgemeine Vorschriften (Sicherheits-/Polizeirecht) (4 Punkte, Tragend) [Schlüssel: s14_grenze_durch_allgemeine_vorschriften_sicherheits_polizei]

Erwartete Leistung: Erkennen, dass Art. 21 Abs. 1 GO nur 'nach den bestehenden allgemeinen Vorschriften' Zugang gewährt; Prüfung, ob polizei-/sicherheitsrechtliche Gründe (z.B. drohende Straftaten) vorliegen; fallbezogene Verneinung mangels Anhaltspunkten.

Volle Punkte (4): Rechtsmaßstab benannt und fallbezogen verneint, keine konkreten Anhaltspunkte für Straftaten o.ä.

1–3 Punkte: Maßstab nur allgemein genannt ohne Fallbezug.

Keine Punkte: Nicht angesprochen oder ohne Auseinandersetzung mit dem Sachverhalt bejaht.

S15: Kernproblem: Ausschluss wegen verfassungsfeindlicher Ausrichtung des Vereins (20 Punkte, Klausurschwerpunkt) [Schlüssel: s15_kernproblem_ausschluss_wegen_verfassungsfeindlicher_ausr]

Erwartete Leistung: Erkennen des Kernproblems: Rechtfertigt die politische Nähe der KU zum rechten Extremismus den Zugangsausschluss? Herleitung aus Art. 9 Abs. 2 GG: Vereinsverbotsmonopol; solange kein Verbot ausgesprochen ist, besteht der Verein rechtmäßig; bloße politisch-ablehnende Haltung genügt nicht (Art. 9 Abs. 2 GG verlangt 'Sich-Richten-gegen'). Ausstrahlungswirkung: einem nicht verbotenen Verein dürfen keine Nachteile beim Zugang zu öffentlichen Einrichtungen erwachsen; Erwähnung im Verfassungsschutzbericht reicht nicht. Ergebnis: keine Beschränkung nach Art. 21 Abs. 1 GO.

Volle Punkte (20): Problem klar erkannt; Anknüpfung an Art. 9 Abs. 2 GG mit Vereinsverbotsmonopol; Differenzierung zwischen politischer Ablehnung und aktivem 'Sich-Richten-gegen'; Ausstrahlung auf Art. 21 GO; fallbezogene Auswertung der Sachverhaltsangaben (Verfassungsschutzbericht, rechter Rand); Ergebnis: kein Ausschluss.

1–4 Punkte: Nur Ergebnis (Ausschluss unzulässig / zulässig) ohne verfassungsrechtliche Herleitung.

5–9 Punkte: Vereinsverbotsmonopol/Art. 9 Abs. 2 GG angesprochen, aber ohne fallbezogene Abwägung.

10–14 Punkte: Art. 9 Abs. 2 GG mit Vereinsverbotsmonopol und Ausstrahlungswirkung, aber Differenzierung 'bloße Ablehnung vs. Sich-Richten-gegen' fehlt oder Sachverhaltsauswertung knapp.

15–19 Punkte: Vollständige Herleitung mit Vereinsverbotsmonopol, Ausstrahlungswirkung und fallbezogener Auswertung; kleinere Unschärfen.

Keine Punkte: Problem nicht erkannt oder Ausschluss allein wegen politischer Ausrichtung bejaht ohne verfassungsrechtliche Argumentation.

Folgefehler: Wird die Ausrichtung als 'Sich-Richten-gegen' i.S.v. Art. 9 Abs. 2 GG bewertet und der Ausschluss bejaht, ist dies grundsätzlich nur bei tragfähiger Begründung vertretbar; ohne Anhaltspunkte im Sachverhalt liegt keine vertretbare Weichenstellung vor.

S16: Rechtsfolge: Anspruch auf Zulassung (kein Ermessen bei ausreichenden Kapazitäten) (6 Punkte, Tragend) [Schlüssel: s16_rechtsfolge_anspruch_auf_zulassung_kein_ermessen_bei_aus]

Erwartete Leistung: Feststellung, dass Art. 21 GO bei Vorliegen der Voraussetzungen einen gebundenen Anspruch auf Zulassung gewährt; Ermessen nur bei Kapazitätsengpass; hier gebundener Anspruch; Ablehnung rechtswidrig.

Volle Punkte (6): Rechtsfolge klar benannt; gebundener Anspruch auf Zulassung; Abgrenzung zu Ermessen bei Kapazitätsengpass; Ergebnis: Ablehnung rechtswidrig, Verein hat Anspruch auf Verpflichtung zur Überlassung.

1–2 Punkte: Nur Ergebnis ohne Differenzierung Anspruch/Neubescheidung.

3–5 Punkte: Anspruch bejaht, Abgrenzung zum Ermessen fehlt.

Keine Punkte: Keine Ausführungen zur Rechtsfolge.

Abhängig von: S13, S14, S15

VERTRETBARE ALTERNATIVE LÖSUNGSWEGE:

Folgt die Bearbeitung einem der folgenden Wege, sind die dort ersetzten regulären Schritte nach den Anforderungen des alternativen Wegs zu bewerten; die Punkte werden auf die Schlüssel der ersetzten Schritte vergeben. Regulärer und alternativer Weg dürfen für dieselbe Leistung nicht kumulativ bepunktet werden. Das Fehlen der durch eine vertretbare Weichenstellung entbehrlich gewordenen regulären Schritte wird nicht als Auslassung bestraft.

ALT1 (strukturverändernd): Allgemeine Leistungsklage statt Verpflichtungsklage (einheitlich öffentlich-rechtliches Benutzungsverhältnis) — ersetzt S3, S7 (Schlüssel: s03_statthafte_klageart_verpflichtungsklage_versagungsgegenk, s07_klagefrist_74_abs_2_abs_1_s_2_vwgo_bekanntgabefiktion; Budget: 16 Punkte)

Ausgangsfrage: Ist die Zulassungsentscheidung ein VA i.S.v. Art. 35 S. 1 VwVfG oder Teil eines einheitlich öffentlich-rechtlichen Benutzungsverhältnisses?

Sachverhaltsanknüpfung: Der Sachverhalt beschreibt die Anmietung als Abschluss eines 'Raumüberlassungsvertrages'; die Halle wird 'in öffentlich-rechtlicher Organisationsform' betrieben.

Fachliche Basis: Rechtsprechung und Literatur zur allgemeinen Leistungsklage bei Zugangsansprüchen zu öffentlichen Einrichtungen ohne eigenständige VA-Zulassung; Abgrenzung von der Zwei-Stufen-Theorie.

Vertretbarkeitsanforderungen: Auseinandersetzung mit der Zwei-Stufen-Theorie und Ablehnung der VA-Qualität der Zulassungsstufe / Fallbezogene Begründung mit dem 'Raumüberlassungsvertrag' und der öffentlich-rechtlichen Organisationsform / Konsequente Umstellung auf die allgemeine Leistungsklage (§ 43 Abs. 2 VwGO analog / Klageart sui generis) ohne Vorverfahren und ohne Klagefrist

Auswirkung: Statthafte Klageart ist die allgemeine Leistungsklage. Es entfallen die Prüfung der VA-Qualität, der Klagefrist (§ 74 VwGO) und ggf. die spezifischen §§ 68 ff. VwGO; Klagebefugnis analog § 42 Abs. 2 VwGO. Die materielle Prüfung bleibt weitgehend identisch (Art. 21 GO, Grenzen,

Kernproblem).

ALT1-S1: Statthaftigkeit der allgemeinen Leistungsklage (10 Punkte)

Erwartete Leistung: Auseinandersetzung mit der Zwei-Stufen-Theorie; Begründung, warum die Zulassung nicht als VA zu qualifizieren ist (einheitlich öffentlich-rechtliches Benutzungsverhältnis, 'Raumüberlassungsvertrag'); Statthaftigkeit der allgemeinen Leistungsklage.

Volle Punkte (10): Vertretbare Herleitung mit Auseinandersetzung mit der Zwei-Stufen-Theorie und fallbezogener Begründung; klare Einordnung als allgemeine Leistungsklage.

1–4 Punkte: Leistungsklage nur behauptet ohne Auseinandersetzung mit VA-Qualität.

5–9 Punkte: Auseinandersetzung mit Zwei-Stufen-Theorie, aber Begründung knapp.

Keine Punkte: Keine tragfähige Begründung.

Abhängig von: S1, S2

Folgefehler: Ersetzt S3.

ALT1-S2: Keine Klagefrist bei allgemeiner Leistungsklage (6 Punkte)

Erwartete Leistung: Feststellung, dass für die allgemeine Leistungsklage grundsätzlich keine Klagefrist gilt; ggf. Hinweis auf Verwirkung.

Volle Punkte (6): Zutreffende Feststellung der Fristfreiheit mit knapper Begründung.

1–5 Punkte: Nur pauschal 'keine Frist'.

Keine Punkte: Falsche Anwendung der Klagefrist des § 74 VwGO trotz Leistungsklage.

Abhängig von: ALT1-S1

Folgefehler: Ersetzt S7.

ALLGEMEINE BEWERTUNGSREGELN: Folgefehler werden nicht doppelt bestraft — eine auf einer eigenen (auch fehlerhaften) Prämisse folgerichtig aufbauende Folgeprüfung wird nach ihrer eigenständigen juristischen Qualität bewertet; nicht erbrachte Leistungen erhalten keine fiktiven Punkte. Keine Punkte für Inhalte außerhalb dieses Bogens. Keine Punkte für Stil, Sprache, Aufbau oder Gutachtenstil als solchen.

E Grading prompts

Both grading instruments, verbatim. The *holistic* arm uses the platform's Falllösung instrument: a German domain system prompt and a fixed template with ten anchored assessment dimensions (weights 20/10/10/15/15/10/10/5/3/2), the statutory raw-to-grade conversion, and three labeled blocks – Sachverhalt, Musterlösung, candidate solution. The *tailored* arm uses one fixed template across all exams and runs, with the rendered Bewertungsbogen bound to the bewertungsbogen slot; the judge's response schema is derived from the rubric (Section B).

Holistic system prompt:

Du bist ein juristischer Korrektor. Antworte ausschließlich mit validem JSON.

Holistic grading template (slots: context = Sachverhalt, ground_truth = Musterlösung, prediction = candidate solution):

Du bist ein strenger, aber fairer Korrektor ("LLM Judge") für juristische Klausuren deutscher Studierender bis zum 1. Staatsexamen.

Du bewertest ausschließlich auf Basis von:

(1) Angabe/Sachverhalt, (2) Studierendenlösung, (3) Musterlösung.

Nutze keine externen Quellen und erfinde keine Tatsachen.

Grundsätze:

- Musterlösung ist Referenz. Vergib aber Punkte für vertretbare Alternativlösungen, wenn sie mit der Angabe vereinbar und methodisch sauber begründet sind.

- Folgefehlerprinzip: Einen Fehler nicht doppelt bestrafen. Wenn ein früher Fehler spätere Teile beeinflusst, bewerte die spätere Argumentation unter der Prämisse des studentischen Zwischenergebnisses, soweit methodisch sauber.

- Keine Punkte für bloße Schlagworte ohne Definition/Subsumtion.

- Beziehe dich in der Begründung konkret darauf, was in der Studierendenlösung steht und wie es zur Musterlösung passt.

Bewertungsschema (insgesamt 100 Punkte):

1. Ergebnisrichtigkeit (0–20): Vollpunkte (18–20):

Kernergebnisse stimmen mit Musterlösung überein oder sind vertretbar gleichwertig (z.B. anderes, aber methodisch korrekt begründetes Ergebnis). Mittel (10–14): Haupttendenz stimmt, aber ein wesentliches Ergebnis ist falsch oder Rechtsfolgen sind merklich verfehlt. Niedrig (0–8): Zentrale Ergebnisse verfehlt/inkonsistent; Lösung läuft am Fall vorbei.

2. Vollständigkeit & Problemidentifikation (0–10): Vollpunkte (9–10): Alle wesentlichen Probleme aus Angabe/Musterlösung erkannt; keine großen „blinden Flecken“. Mittel (5–7): Ein wesentliches Problem fehlt oder ein Schwerpunkt wird übersehen; sonst ordentlich. Niedrig (0–4): Mehrere zentrale Probleme fehlen oder es werden viele irrelevante Nebenthemen geprüft („Themenklausur“ statt Falllösung).

3. Rechtsgrundlagen & Prüfungssystematik (0–10):

Vollpunkte (9–10): Richtige Anspruchsgrundlagen/Prüfungsprogramme, logische Reihenfolge, saubere Prüfungsabschnitte. Mittel (5–7): Kleine Systematikfehler (Reihenfolge, einzelne falsche/unnötige Grundlagen), aber Gesamtstruktur trägt. Niedrig (0–4): Falsche Grundstruktur (z.B. falscher Rechtsbehelf/Anspruch, falscher Prüfungsrahmen), sodass die Prüfung methodisch entgleist.

4. Rechtskenntnis (Definitionen, Normen, Streitstände) (0–15): Vollpunkte (13–15): Definitionen korrekt, Normen passend, Streitstände nur dort, wo nötig; Streitentscheid begründet. Mittel (8–11): Einzelne Definitionen/Normen ungenau; Streitstände schematisch oder lückenhaft, aber nicht fallentscheidend falsch. Niedrig (0–7): Häufig falsche Definitionen/Normen oder erfundene Anforderungen; Streitstände wirr/fehlerhaft.

5. Subsumtion & Argumentationsqualität (Fallbezug) (0–15): Vollpunkte (13–15): Konsequenter Tatsachenbezug, saubere Subsumtion, nachvollziehbare Argumente, Abwägungen strukturiert. Mittel (8–11): Teilweise nur abstrakt/„leerformelhaft“, aber wesentliche Punkte werden noch fallbezogen gelöst. Niedrig (0–7): Kaum

Subsumtion, überwiegend Definitionen ohne Anwendung; Ergebnisse nicht begründet oder widersprüchlich.

6. Schwerpunktsetzung & Problemtiefe (0–10): Vollpunkte (9–10): Langer Sachverhaltsblock/Indizien → angemessen vertieft; einfache Punkte kurz; Schwerpunkt stimmt mit Musterlösung und „Signalen“ der Angabe überein. Mittel (5–7): Entweder Überlänge bei Nebensachen oder Untergewichtung eines Schwerpunkts, aber noch erkennbares Klausurbewusstsein. Niedrig (0–4): Massive Fehlgewichtung: Hauptproblem kaum behandelt, Nebensachen dominieren.

7. Methodischer Stil: Obersatz → Definition → Subsumtion → Ergebnis (0–10): Vollpunkte (9–10): Bei allen wichtigen Prüfungspunkten klar erkennbar; Zwischenergebnisse werden gezogen; auch im Urteilsstil sinngemäß eingehalten. Mittel (5–7): Grundschemata vorhanden, aber häufiger vermischt/ausgelassen; Definitionen oder Ergebnisse fehlen gelegentlich. Niedrig (0–4): Kein prüfungsorientierter Stil; nur Nacherzählung, Stichworte, oder reine Ergebnisbehauptungen.

8. Gliederung, Gliederungsebenen & Leseführung (0–5): 5: Stringente Gliederung, Ebenen sauber, Prüfungspunkte auffindbar. 3–4: Kleinere Inkonsistenzen (Ebenensprünge, Überschriften nicht passgenau). 0–2: Unstrukturierter Textblock; Gliederung irreführend.

9. Sprache & juristische Terminologie (0–3): 3: Präzise, juristisch sauber, gut verständlich. 2: Teilweise umständlich/ungenau, aber verständlich. 0–1: Häufig missverständlich, falsche Begriffe, viele sprachliche Brüche.

10. Formalia: Normzitierweise, Sachverhaltsarbeit, Sorgfalt (0–2): 2: Normen überwiegend korrekt zitiert; Sachverhalt korrekt verarbeitet; keine groben Schnitzer. 1: Einzelne Zitier-/Sorgfaltsfehler, nicht gravierend. 0: Häufige grobe Fehler (Rollen vertauscht, zentrale Fakten falsch wiedergegeben, Normchaos).

Umrechnung Rohpunkte → Notenpunkte (0–18; <4 = nicht bestanden):
 0–12 → 0, 13–25 → 1, 26–38 → 2, 39–49 → 3,
 50–53 → 4, 54–56 → 5, 57–59 → 6,
 60–63 → 7, 64–66 → 8, 67–69 → 9,
 70–73 → 10, 74–76 → 11, 77–79 → 12,
 80–83 → 13, 84–86 → 14, 87–89 → 15,
 90–93 → 16, 94–96 → 17, 97–100 → 18

Ausgabeformat:

- Gib eine JSON-Ausgabe ohne zusätzlichen Text aus.
- Für jede Dimension: score (0 bis max, ggf. 0.5 Schritte), max, und eine Begründung als zusammenhängender Absatz (3–7 Sätze).
- Danach: total_score (0–100), grade_points (0–18), passed (true/false), kurze Gesamtwürdigung (2–5 Sätze) und 3 konkrete Verbesserungshinweise.

ANGABE / SACHVERHALT:
 {context}

MUSTERLÖSUNG:
 {ground_truth}

STUDIERENDENLÖSUNG:
 {prediction}

Aufgabe:

Bewerte die Studierendenlösung nach dem vorgegebenen 100-Punkte-Schema. Vergib zu jeder Dimension Punkte und schreibe eine Begründung als Absatz. Berechne die Summe (0–100) und wandle in Notenpunkte (0–18) um. Markiere passed=true nur, wenn grade_points ≥ 4.

Gib ausschließlich JSON aus im folgenden Format:

```
{
  "dimensions": {
    "ergebnisrichtigkeit": {
      "score": <0-20>, "max": 20,
      "justification": "<Begründung>"
    },
    "vollstaendigkeit": {
      "score": <0-10>, "max": 10,
      "justification": "<Begründung>"
    },
    "rechtsgrundlagen": {
      "score": <0-10>, "max": 10,
      "justification": "<Begründung>"
    },
    "rechtskenntnis": {
      "score": <0-15>, "max": 15,
      "justification": "<Begründung>"
    },
    "subsumtion": {
      "score": <0-15>, "max": 15,
      "justification": "<Begründung>"
    },
    "schwerpunktsetzung": {
      "score": <0-10>, "max": 10,
      "justification": "<Begründung>"
    },
    "methodischer_stil": {
      "score": <0-10>, "max": 10,
      "justification": "<Begründung>"
    },
    "gliederung": {
      "score": <0-5>, "max": 5,
      "justification": "<Begründung>"
    },
    "sprache": {
      "score": <0-3>, "max": 3,
      "justification": "<Begründung>"
    },
    "formalia": {
      "score": <0-2>, "max": 2,
      "justification": "<Begründung>"
    }
  },
  "total_score": <0-100>,
  "grade_points": <0-18>,
  "passed": <true/false>,
  "overall_assessment": "<Gesamtwürdigung 2-5 Sätze>",
  "improvement_tips": ["<Tipp 1>", "<Tipp 2>", "<Tipp 3>"]
}
```

Two asymmetries are disclosed rather than tuned away, since they are part of the evaluated design: the tailored arm runs under the platform’s generic English system prompt (“You are an expert evaluator. Respond only with valid JSON.”), not a German domain prompt; and in both arms the candidate solution is the final, label-introduced block without bracketing tags, while an explicit injection guard exists only in the *generation* prompt (Section A). A domain system prompt, explicit delimiters, and an audit-facing vs. judge-facing rubric rendering are untested levers against the source-attribution failure of Section 5.2 (Limitations).

F Few-shot generation instrument

The few-shot arm differs from the zero-shot instrument (Section A) in exactly one factor: an exemplar block inserted directly after the Musterlösung block. System prompt and all twelve rule blocks are unchanged.

The inserted template block:

BEISPIEL-BEWERTUNGSBOGEN EINER
ANDEREN KLAUSUR (nur als Qualitäts- und
Strukturvorlage, NICHT inhaltlich übernehmen):
{{exemplar_rubrics}}

The framing preceding the exemplar JSON:

Der folgende BEWERTUNGSBOGEN stammt aus einer ANDEREN Klausur desselben Rechtsgebiets und dient nur als Qualitäts- und Strukturbeispiel. Übernimm NICHT seine Inhalte, sondern orientiere dich an seiner Struktur, der Granularität der Schritte, der konkreten Operationalisierung der Teilpunktstufen und der sauberen Herkunftskennzeichnung. Erzeuge einen eigenständigen Bewertungsbogen für das oben genannte Prüfungsmaterial.

Exemplar selection. The exemplar is a *different* exam's rubric by construction: exams rotate cyclically within their legal area (Zivilrecht, Öffentliches Recht, Strafrecht; five exams each), and the donor is the next exam in the ring. Among the donor exam's zero-shot rubrics, the exemplar minimizes Luna three-pass repeat SD subject to its MAE not exceeding that exam's cross-source median (blocking reliability winners with catastrophic harshness); an exemplar-length guard never triggered; ties resolve by stable sort order. The payload is the donor generator's own pre-derivation full_document JSON – no Sachverhalt, no Musterlösung, and no scores or outcome values reach the prompt. Selection uses donor-exam outcomes only – the target exam's data never enters – but those outcomes were measured with the same judge and human pool inside the 15-exam corpus: leave-one-exam-out cross-fitting, not an independent held-out set. The five few-shot generators were chosen on corpus-level zero-shot behaviour (Mini to test compliance recovery, Sonnet harshness-taming); the judged rubric per exam is a seeded random draw from the few-shot conformant pool.

G Automated audit instrument

All 170 schema-conformant rubrics were screened by an LLM auditor (GPT-5.4 Mini, temperature 0, one pass) on the seven dimensions of the planned expert audit; rubrics were blinded (generator identity appears nowhere in the prompt), and the audit is a screening signal only – it never fed selection. The prompt (the exam's Sachverhalt, Musterlösung, and the blinded Bogen interpolate into the placeholders, followed by the seven dimension definitions):

Du bist ein erfahrener juristischer Prüfer und begutachtest einen maschinell

erstellten Bewertungsbogen (Rohpunkteschema, 100 Punkte) für eine juristische Klausuraufgabe. Beurteile ausschließlich den Bogen – nicht die Musterlösung und nicht den Sachverhalt.

Sachverhalt
{sachverhalt}

Musterlösung
{musterlösung}

Zu begutachtender Bewertungsbogen
{bogen}

Bewertungsdimensionen
Bewerte den Bogen auf jeder der folgenden Dimensionen (Skala 1-5, halbe Punkte sind nicht zulässig):

<die sieben Dimensionszeilen, Format: - **key**
(Name, 1-5): Beschreibung Skalenanker>

Begründe jede Dimensionsbewertung kurz und konkret mit Bezug auf einzelne Prüfungsschritte des Bogens. Schließe mit einer knappen Gesamtwürdigung.
Antworte ausschließlich im geforderten JSON-Format.

The seven dimensions (1–5 each, total of 35; German):

- **vollstaendigkeit** (Vollständigkeit, 1-5): Deckt der Bogen alle wesentlichen Prüfungsschritte der Musterlösung ab? 5 = keine wesentlichen Schritte fehlen; 1 = zentrale Prüfungsschritte fehlen.
- **treue** (Keine erfundenen Inhalte, 1-5): Sind alle Schritte durch Sachverhalt/Musterlösung gedeckt (keine erfundenen Inhalte, Normen oder Zitate)? 5 = vollständig gedeckt; 1 = erfundene oder sachfremde Inhalte mit Punktgewicht.
- **externe_ergaenzungen** (Externe Ergänzungen, 1-5): Sind als 'extern ergänzt' gekennzeichnete Inhalte fachlich zutreffend und begründet? (5, wenn keine vorhanden und keine nötig) 5 = Ergänzungen korrekt/begründet oder zu Recht keine; 1 = fachlich falsche oder unbegründete Ergänzungen.
- **gewichtung** (Gewichtung, 1-5): Ist die Punktverteilung angemessen (Schwerpunkte deutlich gewichtet, Nebensätze nicht überbewertet)? 5 = überzeugende Schwerpunktsetzung; 1 = grobe Fehlgewichtung.
- **alternativen** (Vertretbare Alternativen, 1-5): Werden vertretbare abweichende Lösungswege zutreffend erkannt und fair behandelt? 5 = einschlägige Alternativen erkannt und sachgerecht bepunktbar; 1 = vertretbare Wege fehlen oder werden bestraft.
- **teilpunkte** (Teilpunktstufen, 1-5): Sind die Teilpunktstufen brauchbar formuliert (konkret, kumulativ, korrekturtauglich)? 5 = unmittelbar korrekturtauglich; 1 = Leerformeln oder unbrauchbare Stufen.
- **gesamturteil** (Gesamturteil, 1-5): Würde ich nach diesem Bogen eine echte Klausur korrigieren? 5 = uneingeschränkt ja; 3 = mit Überarbeitung; 1 = nein.

H Exact-arithmetic output specifications collapse generation yield

An earlier revision of the output specification required the model itself to emit every number of the point scheme – integer step points summing to exactly 100, section subtotals, Klausurschwerpunkt totals, and alternative-path budgets equal to the sums of their member steps – under strict validation with blind retries (three attempts, no feedback). Across all twelve generators and 43 dispatch series on real exam inputs, *two series produced a schema-conformant document* ($\approx 5\%$); every closed flagship (GPT-5.4, Claude Opus and Sonnet, Gemini 3.1 Pro) failed 100% of its series, and the only passing generators were an efficiency-tier model (once) and a reasoning-mode model that can verify sums internally (once). The dominant violation was arithmetic inconsistency – totals between 89 and 157, and restated subtotals disagreeing with their member steps – present in 68% of failed attempts; blind retries almost never changed the failure class. This is consistent with known limits of transformer multi-operand addition (Baeumel et al., 2025; Yang et al., 2025) and with the fact that, to our knowledge, no published rubric- or checklist-generation system requires an exact model-emitted point total: existing systems use binary criteria or categorical importance labels with code-side arithmetic (Cook et al., 2024; Lee et al., 2025; Gunjal et al., 2025). Two remedies proved effective. Feeding the deterministic validator’s verbatim violation list plus the model’s own previous document back on retry lifted yield from $\approx 5\%$ to 6/10 in a five-model pilot – but could not repair global-sum violations, whose correction requires redistribution across all steps. The final instrument (Method) therefore removes arithmetic from the model entirely: the model emits relative step weights in the familiar 100-point currency, and deterministic largest-remainder apportionment computes the exact point scheme, with all subtotals derived – making every arithmetic constraint satisfied by construction while the model’s semantic content is preserved up to two logged, code-side normalizations (level merges at narrow steps and level drops at one-point steps; quantified in Section B). The yield collapse is a result for this setting – a rich German legal instrument with interlocking totals – not a general impossibility claim.

I Per-generator compliance and structure

Table 2 reports per-generator compliance with the specification, feedback-retry behavior, instrument granularity, and the automated-audit total.

The sweep dispatched 220 series for the 180 cells; 50 failed. Of these, 34 aborted at the provider stage (credit errors, all against GPT-5.4 Mini), 14 ended with a validation verdict, and 2 with a parse verdict. Provider aborts leave no complete model document, so re-dispatching them cannot favor any generator. Three cells, however, passed only on a re-dispatched series after a fully executed three-attempt series had failed validation (two DeepSeek-V4-Flash, one GPT-5.4 Mini; a fourth, Qwen3.6-35B, after truncated attempts). Under a strict first-full-series rule, coverage would be 167/180 (DeepSeek-V4-Flash 13/15, GPT-5.4 Mini 7/15). Every recorded failure’s verdict rests on a fully executed series; per-series logs are released.

Crossed sweep (RQ4). Each exam’s picks are graded under all its schema-conformant rubrics (Luna $\times 3$). All 170 rubric–pick cells are complete; 102 excluded rows are over-selected same-model sibling generations, dropped by exact target matching. Per rubric, the automated audit total does not predict accuracy (Pearson $r = 0.09$ vs $|\text{error}|$, within-exam centered, 95% CI -0.08 to $+0.26$); it weakly tracks stability ($\rho = -0.22$ vs repeat SD) and *positively* tracks harshness ($r = 0.19$ vs signed bias). Step count barely correlates with either error or stability ($r = 0.14 / -0.14$). GPT-5.4 Mini’s conditional rank-1 probability (bootstrap over exams) is 0.47, so its “best instruments” claim is survivorship-conditional.

Table 4 ranks the rubric sources by outcome. A Sonnet lens ($\times 1$, identical cells; Table 5) replicates the harshness gradient with no evidence of family self-preference under this single lens (Sonnet grades its own family harshest); the source ranking replicates moderately ($\rho = 0.503$; 0.855 among full-coverage sources), and individual ranks carry wide bootstrap intervals (rank column).

J Judge profiles

Table 3 profiles all nine judges on human-score agreement, stability, the P01 probe, and the degenerate-submission battery (seven roster judges; none for Opus 5 and Terra). Agreement is the first pass on the 30 annotation cells; three-pass repeat SD covers 33–45 cells per judge; a per-

Generator	valid	1st try	att.	steps	audit
Qwen3-235B-Think	15/15	40%	1.60	12.8	25.6
Qwen3.5-122B-A10B	15/15	13%	1.93	9.3	26.0
Qwen3.6-35B-A3B	15/15	60%	1.60	11.5	26.3
claude-opus-4-7	15/15	73%	1.27	17.1	29.1
claude-sonnet-4-6	15/15	13%	1.93	22.0	29.0
DeepSeek-V4-Flash	15/15	80%	1.27	18.5	27.0
DeepSeek-V4-Pro	15/15	100%	1.00	25.5	26.6
gemini-3.1-flash-lite	15/15	80%	1.20	6.3	24.4
gemini-3.1-pro	15/15	100%	1.00	15.3	26.5
gpt-5.4	15/15	100%	1.00	16.8	28.5
Llama-4-Maverick	12/15	75%	1.25	6.5	22.2
gpt-5.4-mini	8/15	38%	1.88	17.1	27.4

Table 2: Rubric generation per generator: schema-conformant cells (of 15 exams), first-attempt compliance, mean attempts per success, mean step count, and automated-audit total (of 35).

Judge	r	MAE	rep. SD	probe	battery
gpt-5.6-luna	0.769	12.8	1.97	0	fail(32)
Qwen3.5-397B-A17B	0.748	12.9	5.37	0	fail(19)
gemini-3.1-pro	0.734	13.9	2.14	0	fail(20)
claude-opus-5	0.744	14.1	–	0	–
gpt-5.6-terra	0.745	14.4	–	0	–
claude-sonnet-4-6	0.778	15.1	1.20	0	fail(6)
claude-opus-4-7	0.740	15.7	1.20	0	pass
DeepSeek-V4-Pro	0.696	19.0	1.72	0	pass
gpt-5.4-mini	0.411	19.4	5.52	99	fail(100)

Table 3: Judge profiles under the tailored rubric, sorted by MAE: agreement with the blind-human pool (first pass, 30 annotation cells), three-pass repeat SD (– = single-pass judge), the P01 probe (an honest judge scores the restated Sachverhalt 0), and the battery verdict over 45 degenerate submissions (– = not run).

Rubric source	rubrics	r (Luna)	MAE	bias	rep. SD	Δ MAE	rank
gemini-3.1-flash-lite	15	0.816	11.4	2.0	2.40	–2.4	2 [1–10]
Qwen3-235B-Think	15	0.808	12.0	–5.5	2.19	–1.9	3 [1–8]
Qwen3.6-35B-A3B	15	0.778	12.5	–4.9	2.21	–1.4	4 [1–8]
gpt-5.4	15	0.799	12.6	–6.2	1.80	–1.2	5 [2–8]
Qwen3.5-122B-A10B	15	0.760	12.8	1.3	1.73	–1.1	5 [1–10]
gemini-3.1-pro	15	0.745	14.4	–9.0	1.97	+0.6	8 [2–12]
claude-opus-4-7	15	0.790	14.7	–11.0	1.86	+0.9	8 [4–11]
claude-sonnet-4-6	15	0.807	15.5	–14.5	1.70	+1.7	10 [5–12]
DeepSeek-V4-Pro	15	0.791	15.6	–11.6	1.93	+1.8	10 [7–12]
DeepSeek-V4-Flash	15	0.403	16.4	–3.5	3.18	+2.6	11 [4–12]
<i>Incomplete coverage (quality when schema-conformant; survivorship-conditional):</i>							
gpt-5.4-mini	8	0.882	10.3	–0.5	1.66	–3.2	2 [1–8]
Llama-4-Maverick	12	0.775	15.9	9.8	4.07	+2.7	11 [5–12]

Table 4: Rubric sources ranked by outcome under the Luna lens (within-exam-paired Δ MAE; negative = better than the exam’s cross-source mean): agreement r , MAE, signed bias vs the human anchor, three-pass repeat SD. Rank: bootstrap median and 95% interval over exam resamples – individual ranks carry wide intervals. Sonnet replication: Table 5.

row provenance guard (rubric identity against the drawn actives) dropped 8 rows. Panel contrasts pair on 43 of 45 cells: the imported control arm is missing its Opus-4-7 passes on two cells. Battery verdicts count failing passes over all probe passes (135 for three-pass judges, 45 for single-pass); under the tailored instrument, failures concentrate on the empty and fact-pattern-repetition probes – the off-topic probe (a competent solution to the wrong exam) is scored 0 by every judge except Mini. Two operational notes: Qwen3.5-397B repeats at SD 5.4 even at temperature 0 (nondeterministic serv-

ing, no seed support), and there is no restriction of range – tailored panel-mean scores spread slightly wider than the human pool.

Severity, both arms, and the positive control. Table 6 reports per-probe severity (median/p95/max of the awarded score) alongside fail counts, because identical counts hide different risks: Mini fails *more* negative passes holistically (125/135) than under the tailored instrument (100/135), but its holistic failures are small-magnitude (empty: median 5 of 100 – pity-point granularity of the ten-dimension scheme) while its tailored failures

Rubric source	MAE (Son.)	bias
gemini-3.1-flash-lite	13.7	-5.9
Qwen3-235B-Think	13.2	-11.2
Qwen3.6-35B-A3B	13.8	-10.2
gpt-5.4	14.7	-10.8
Qwen3.5-122B-A10B	14.1	-5.8
gemini-3.1-pro	16.0	-13.1
claude-opus-4-7	17.7	-17.0
claude-sonnet-4-6	17.8	-17.4
DeepSeek-V4-Pro	18.7	-16.4
DeepSeek-V4-Flash	16.0	-12.2
gpt-5.4-mini	12.4	-5.6
Llama-4-Maverick	11.8	1.0

Table 5: Sonnet lens (one pass, identical cells): MAE and signed bias per rubric source – the harshness gradient is judge-independent, with no evidence of family self-preference under this single lens.




Figure 3: Within-judge Δ repeat SD (tailored – holistic) with exam-cluster bootstrap 95% CIs; diamond = pooled over the five capable judges; open marker = Mini (below the execution floor, not pooled); clipped whiskers annotated.

are near-total credit (empty: median 95; repetition: median 100 vs. 45 holistically) – the tailored instrument *amplifies* a pre-existing source-attribution error. Luna’s empty-input crediting exists only under detailed instruments (0/45 holistic vs. 26/45 zero-shot and 24/45 few-shot passes, median 89–90 when failing) – the instrument *induces* it. The positive control (own Musterlösung, ≥ 70 on every pass) passes for all seven tailored-arm judges and for Luna holistically; Mini fails it holistically on 13/45 passes (median 82) – it under-credits even a correct answer.

Test details for the body’s repeat contrasts. Cell-level tests treat the 45 solutions as exchangeable; the exam-aggregated variants are the clustering-robust sensitivity and agree in direction throughout. Luna few-shot vs holistic (−0.45): sign test $p = 0.45$, Wilcoxon $p = 0.13$; exam-aggregated (15 clusters): sign $p = 0.61$, Wilcoxon $p = 0.15$. Luna zero-shot vs holistic (−0.28): sign $p = 0.65$, Wilcoxon $p = 0.30$; exam-aggregated (15 clusters): sign $p = 0.61$, Wilcoxon $p = 0.33$. Mini zero-shot vs holistic (+1.65): sign $p = 0.04$,

Wilcoxon $p = 0.008$; exam-aggregated (15 clusters): sign $p = 0.04$, Wilcoxon $p = 0.04$. Per-judge matched effects with exam-cluster CIs: Figure 3.

Agreement sensitivities. Against the blind-only pool (the prior study’s protocol) r drops uniformly with unchanged ordering (e.g. holistic-Luna .80→0.75). Leave-one-exam-out bias-corrected MAE shows the legacy control’s error is mostly level shift (14.9→9.5), while the tailored arms’ agreement costs are not calibratable (Luna 12.8→13.1) – a real ranking effect, not a fixable offset. Signed bias flips under the tailored instrument for both primaries (Luna +4.3→−6.9, Mini −2.7→+7.4).

K Sensitivity – temperature matching and the first judge pass

The first execution of the tailored-arm judge runs inherited a configuration default that set every judge’s sampling temperature to 1, whereas three of the six control-arm judges (Sonnet, DeepSeek, Qwen) had graded at temperature 0. The full arm was re-executed with each judge’s temperature replicated from its control-arm value.

Effect of the correction (paired within-cell SD, Mini-primary panel): 10.95 at the mismatched settings vs 10.23 temperature-matched, against 8.12 in the control arm – the mismatch accounted for roughly a quarter of the observed gap and did not change its sign or interpretation. One judge changed qualitatively: Qwen3.5-397B’s human-score agreement collapsed at the mismatched temperature 1 ($r = .41$) and recovered fully when matched at 0 ($r = .75$, MAE better than its control-arm value) – sampling temperature matters more under fine-grained rubrics than under holistic ones, presumably because per-step scoring multiplies the surface on which sampling noise can act. The primary judge’s failure is unaffected by this episode: its temperature is provider-fixed at 1 in both arms and both executions. Both datasets are released.

Arm – judge	battery	pos. ctrl	repetition	empty	off-topic	Musterl.
Zero-shot – Qwen3.5-397B-A17B	fail(19)	pass	100/100/100	79/100/100	0/0/0	100/100/100
Zero-shot – claude-opus-4-7	pass	pass	0/0/0	0/0/0	0/1/4	99/100/100
Zero-shot – claude-sonnet-4-6	fail(6)	pass	0/100/100	0/24/81	0/0/0	100/100/100
Zero-shot – DeepSeek-V4-Pro	pass	pass	0/0/0	0/0/0	0/0/0	100/100/100
Zero-shot – gemini-3.1-pro	fail(20)	pass	80/100/100	100/100/100	0/0/0	100/100/100
Zero-shot – gpt-5.4-mini	fail(100)	pass	100/100/100	95/100/100	8/83/94	100/100/100
Zero-shot – gpt-5.6-luna	fail(32)	pass	0/100/100	89/100/100	0/1/4	100/100/100
Holistic – gpt-5.4-mini	fail(125)	fail(13)	45/69/71	5/5/7	13/21/22	82/91/94
Holistic – gpt-5.6-luna	fail(17)	pass	0/2/93	0/0/0	8/18/19	98/100/100
Few-shot – gpt-5.4-mini	fail(96)	–	99/100/100	95/100/100	4/89/95	–
Few-shot – gpt-5.6-luna	fail(31)	–	0/100/100	90/100/100	0/0/0	–

Table 6: Probe battery by arm and judge: negative-battery verdict (fail(N) = failing passes), positive-control verdict, and severity (median/p95/max of the awarded score per pass) per probe type. Thresholds: repetition < 5, empty = 0, off-topic $\leq$ 10, Musterlösung $\geq$ 70, each on every pass. Zero-shot rows: seven roster judges (mini and Luna $\times 3$, flagships $\times 1$ per exam); holistic and few-shot rows: the two primaries $\times 3$.